

**MODEL PREDIKSI HASIL PRODUKSI KELAPA SAWIT
BERDASARKAN FAKTOR LINGKUNGAN DAN PERAWATAN
MENGUNAKAN METODE
LONG SHORT-TERM MEMORY
(Studi Kasus : PTPN IV REGIONAL 6 KSO)**

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan
Pendidikan Jenjang Sarjana Terapan
Pada Politeknik Negeri Lhokseumawe



Oleh:

MUHAMMAD RIVAL

NIM	: 2021573010054
Program Studi	: Teknik Informatika
Jurusan	: Teknologi Informasi dan Komputer

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN
TEKNOLOGI POLITEKNIK NEGERI LHOKSEUMAWE
2025**

PENGESAHAN PEMBIMBING

Skripsi yang berjudul *Model Prediksi Hasil Produksi Kelapa Sawit Berdasarkan Faktor Lingkungan Dan Perawatan Menggunakan Metode Long Short-Term Memory (Studi Kasus : PTPN IV REGIONAL 6 KSO)*, disusun oleh Muhammad Rival, NIM 2021573010054, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe telah memenuhi syarat untuk dipertanggungjawabkan di hadapan dewan penguji.

Pembimbing I,

Buket Rata,

Pembimbing II ,

Dr. Rahmad Hidayat, S.Kom., M.Cs.

NIP. 19830420 201212 1 003

Muhammad Reza Zulman, S.S.T, M.Sc.

NIP. 19920501 202203 1 005

Mengetahui:

Ketua Jurusan

Teknologi Informasi dan Komputer,

Ketua Program Studi

Teknik Informatika,

Salahuddin, ST., M.Cs.

NIP. 19740424 200212 1 002

M. Khadafi, S.T., M.T.

NIP. 19750718 200212 1 004

PENGESAHAN PENGUJI

Skripsi yang berjudul *Model Prediksi Hasil Produksi Kelapa Sawit Berdasarkan Faktor Lingkungan Dan Perawatan Menggunakan Metode Long Short-Term Memory (Studi Kasus : PTPN IV REGIONAL 6 KSO)*, disusun oleh Muhammad Rival, NIM 2021573010054, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe, telah dipertanggung jawabkan di depan dewan penguji dan dinyatakan lulus pada tanggal 31 Juli 2025.

Komisi Sidang,

Muhammad Rizka, S.S.T., M.Kom.	
NIP. 19881009 201504 1 001	(Ketua Sidang)

Radhiyatammardhiyyah, S.S.T., M.Sc.	
NIP. 19922082 6202203 2 011	(Sekretaris Sidang)

Muhammad Arhami, S.Si., M.Kom.	
NIP. 19741029 200003 1 001	(Penguji I)

Azhar, S.T., M.T.	
NIP. 19640830 199003 1 005	(Penguji II)

Musta'inul Abdi, S.S.T., M.Kom.	
NIP. 19911030 201903 1 015	(Penguji III)

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M. Cs.
NIP. 19740424 200212 1 002

M. Khadafi, S.T., M.T.
NIP. 19750718 200212 1 004

HALAMAN PERNYATAAN

Dengan ini saya menyatakan bahwa dalam skripsi ini tidak terdapat karya yang pernah diajukan untuk mendapatkan gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis orang lain, kecuali yang secara tertulis diacu dalam naskah dan disebut dalam daftar pustaka.

Buket Rata, 22 Juli 2025

Muhammad Rival
NIM. 2021573010054

KATA PENGANTAR

Segala puji beserta syukur senantiasa penulis panjatkan kehadirat Allah SWT yang telah memberikan rahmat, hidayah, dan petunjuk-Nya kepada penulis sehingga penulis dapat menyelesaikan skripsi yang berjudul “Model Prediksi Hasil Produksi Kelapa Sawit Berdasarkan Faktor Lingkungan Dan Perawatan Menggunakan Metode *Long Short-Term Memory* (Studi Kasus : PTPN IV REGIONAL 6 KSO)” tepat pada waktunya. Shalawat beriring salam kepada Nabi Muhammad SAW beserta keluarga dan para sahabat beliau. Skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan pendidikan Diploma IV Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe.

Dalam kesempatan ini, penulis ingin menyampaikan rasa terima kasih yang setulus-tulusnya kepada:

1. Allah Swt. atas limpahan rahmat, hidayah, dan kekuatan yang selalu mengiringi penulis dalam menghadapi setiap kesulitan, serta menjadi sumber ketenangan dan harapan di setiap langkah.
2. Kedua orang tua Supriyatno dan Mainah, S.Pd, serta abang kandung saya yang memberikan dukungan, doa, dan cinta yang tiada hentinya, selama proses pengerjaan skripsi.
3. Bapak Ir. Rizal Syahyadi, S.T., M.Eng.Sc., IPM., ASEAN Eng., APEC Eng. selaku Direktur Politeknik Negeri Lhokseumawe.
4. Bapak Salahuddin, S.T., M.Cs. selaku Ketua Jurusan Teknologi Informasi dan Komputer yang telah memberikan bimbingan dan dukungan selama masa studi.
5. Bapak Muhammad Nasir, S.T., M.T. selaku Sekretaris Jurusan Teknologi Informasi dan Komputer yang telah memberikan bimbingan dan dukungan selama masa studi.
6. Bapak M. Khadafi, S.T., M.T. selaku Ketua Program Studi Teknik Informatika yang telah memberikan arahan dan masukan berharga.

7. Bapak Dr. Rahmad Hidayat, S.Kom., M.Cs dan Bapak Muhammad Reza Zulman, SST, M.Sc selaku dosen pembimbing yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan bimbingan, arahan, serta masukan yang tak ternilai harganya mulai dari awal hingga akhir penyusunan skripsi ini.
8. Seluruh Dosen pengajar Program Studi Teknik Informatika yang telah memberikan ilmunya kepada penulis selama masa perkuliahan.
9. Teman-teman seangkatan TI 2021 yang telah kebersamai suka dan duka selama proses pengerjaan skripsi.
10. Serta semua pihak yang terlibat yang telah banyak membantu penulis selama proses pengerjaan skripsi ini.

Penulis menyadari bahwa skripsi ini masih jauh dari kata sempurna. Oleh karena itu, kritik dan saran yang membangun dari pembaca sangat penulis harapkan untuk perbaikan di masa mendatang.

Akhir kata, semoga skripsi ini dapat memberikan manfaat dan kontribusi yang positif dalam pengembangan ilmu pengetahuan dan teknologi. Penulis berharap agar hasil penelitian ini dapat menjadi sumbangan kecil dalam memajukan bidang Sistem Informasi dan Teknologi Informasi. Semoga Allah SWT senantiasa memberikan rahmat dan hidayah-Nya kepada kita semua.

Buket Rata, 22 Juli 2025

Muhammad Rival

NIM. 2021573010054

ABSTRAK

Industri kelapa sawit di Indonesia memainkan peran penting sebagai penggerak ekonomi nasional, menyumbang lebih dari 50% pasar minyak sawit global dan menciptakan lapangan kerja bagi jutaan orang, terutama di wilayah pedesaan. Namun, tantangan dalam pengembangan model prediksi hasil produksi kelapa sawit meliputi penanganan data deret waktu yang kompleks, termasuk dependensi jangka panjang antara faktor lingkungan, perawatan tanaman, dan variabilitas produksi, yang sering kali menyebabkan ketidakakuratan prediksi dan menghambat optimalisasi operasional. Penelitian ini bertujuan untuk mengatasi tantangan tersebut melalui perancangan, implementasi, dan optimasi model prediksi hasil produksi kelapa sawit menggunakan algoritma *Long Short-Term Memory* (LSTM) di PTPN IV REGIONAL 6 KSO. Model ini dirancang secara spesifik untuk memprediksi data deret waktu (*time series*) dengan dua lapisan LSTM berurutan (128 dan 64 unit) dan dioptimalkan menggunakan algoritma Adam. Model memanfaatkan data deret waktu terkait faktor lingkungan (curah hujan), perawatan tanaman (pemupukan), dan hasil produksi sebagai variabel utamanya, yang dikumpulkan dari catatan perusahaan PTPN IV REGIONAL 6 KSO dan *Google Earth Engine*. Model dievaluasi dengan metrik *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *R² Score*, menghasilkan MAE 1.967.065 (sekitar 3% dari rata-rata nilai aktual sebesar 69.854.418), RMSE 2.833.346 (sekitar 4% dari rata-rata nilai aktual sebesar 69.854.418), dan *R² Score* 0.81, menunjukkan bahwa model menjelaskan 81% variabilitas data produksi dengan tingkat kesalahan prediksi yang rendah.

Kata Kunci : *LSTM*, prediksi produksi, PTPN IV, sistem berbasis web, kelapa sawit.

ABSTRACT

The palm oil industry in Indonesia plays a crucial role as a driver of the national economy, contributing more than 50% of the global palm oil market and creating employment for millions, especially in rural areas. However, challenges in developing predictive models for palm oil production include handling complex time-series data, such as long-term dependencies among environmental factors, crop management, and production variability, which often result in inaccurate forecasts and hinder operational optimization. This study aims to address these challenges through the design, implementation, and optimization of a palm oil production prediction model using the Long Short-Term Memory (LSTM) algorithm at PTPN IV REGIONAL 6 KSO. The model is specifically designed to forecast time-series data with two sequential LSTM layers (128 and 64 units) and is optimized using the Adam algorithm. It leverages time-series data on environmental factors (rainfall), crop management (fertilization), and production as the primary variables, collected from PTPN IV REGIONAL 6 KSO company records and Google Earth Engine. The model was evaluated using Mean Absolute Error (MAE), Root Mean Square Error (RMSE), and R^2 Score, producing an MAE of 1,967,065 (approximately 3% of the actual mean value of 69,854,418), an RMSE of 2,833,346 (approximately 4% of the actual mean value of 69,854,418), and an R^2 Score of 0,81, indicating that the model explains 81% of the variability in production data with a low level of prediction error.

Keywords: *LSTM, production forecasting, PTPN IV, web-based system, palm oil.*

DAFTAR ISI

PENGESAHAN PEMBIMBING.....	ii
PENGESAHAN PENGUJI.....	iii
HALAMAN PERNYATAAN	iv
KATA PENGANTAR	v
ABSTRAK	vii
<i>ABSTRACT</i>	viii
DAFTAR ISI.....	ix
DAFTAR GAMBAR	xi
DAFTAR TABEL.....	xiii
DAFTAR LAMPIRAN.....	xiv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang Masalah.....	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah.....	2
1.4 Tujuan Penelitian.....	3
1.5 Manfaat Penelitian.....	3
1.6 Sistematika Penulisan.....	3
BAB II TINJAUAN PUSTAKA.....	5
1.1 <i>State of The Art</i>	5
1.2 Kelapa Sawit	9
1.3 <i>Machine Learning</i>	10
1.4 <i>Recurrent Neural Network (RNN)</i>	11
1.5 <i>Deep Learning</i>	12
1.6 <i>Long Short-Term Memory</i>	13
1.7 <i>Progressive Web App (PWA)</i>	16
1.8 <i>Prototyping</i>	17
1.9 MAE (<i>Mean Absoulute Error</i>)	18
1.10RMSE (<i>Root Mean Square Error</i>)	19
1.11R2 <i>Score</i>	19
BAB III METODE PENELITIAN.....	21
3.1 Rancangan Sistem	21

3.2 Data dan Pengumpulan Data.....	45
3.3 Rancangan Model.....	49
3.4 Teknik Pengujian.....	53
3.5 Hasil yang diharapkan.....	60
BAB IV HASIL DAN PEMBAHASAN	61
4.1 Hasil Implementasi Sistem.....	61
4.2 Pengelolaan Data.....	69
4.3 Implementasi Model.....	73
4.4 Hasil Pengujian	76
BAB V KESIMPULAN	92
5.1 Kesimpulan.....	92
5.2 Saran.....	93
DAFTAR PUSTAKA	94
LAMPIRAN.....	97
Lampiran 1. <i>Script</i> Pembuatan Dataset <i>Dummy</i>	97
Lampiran 2. <i>Script</i> Pengambilan Data Curah Hujan.....	99
Lampiran 3. Hasil Perhitungan MAE.....	100
Lampiran 4. Hasil Perhitungan RMSE.....	102
Lampiran 5. Hasil Perhitungan <i>R2 Score</i>	104

DAFTAR GAMBAR

Gambar 2. 1 Skema Artificial Intellegend (AI) dan Machine Learning	11
Gambar 2. 2 Diagram Venn Hirarki Artificial Intelegence.....	13
Gambar 2. 3 Alur Proses LSTM	14
Gambar 2. 4 Alur proses Prototyping	17
Gambar 3. 1 Use Case Diagram.....	24
Gambar 3. 2 <i>Activity Diagram</i> Login.....	27
Gambar 3. 3 <i>Activity</i> Proses Prediksi Hasil Produksi	28
Gambar 3. 4 <i>Activity</i> Kelola Data <i>Time Series</i>	29
Gambar 3. 5 <i>Activity</i> Input Data <i>Real-time</i>	30
Gambar 3. 6 <i>Acitivity Diagram</i> Lihat Hasi Prediksi	31
Gambar 3. 7 <i>Acitivity Diagram</i> Mengunduh Laporan	32
Gambar 3. 8 <i>Class Diagram</i>	33
Gambar 3. 9 <i>Flowchart Sistem</i>	34
Gambar 3. 10 Arsitektur Umum Sistem Prediksi Hasil Produksi.....	35
Gambar 3. 11 <i>Interface</i> Login Petugas Lapangan.....	37
Gambar 3. 12 <i>Interface</i> Beranda Petugas Lapangan.....	38
Gambar 3. 13 <i>Interface</i> Login.....	39
Gambar 3. 14 <i>Interface Dashboard</i>	39
Gambar 3. 15 <i>Interface</i> Data Karyawan	40
Gambar 3. 16 <i>Interface</i> Afdeling	41
Gambar 3. 17 <i>Interface</i> Dataset Sistem.....	42
Gambar 3. 18 <i>Interface</i> Curah Hujan.....	42
Gambar 3. 19 <i>Interface</i> Prediksi	43
Gambar 3. 20 <i>Interface</i> Arsip Prediksi	44
Gambar 3. 21 <i>User Interface</i> Laporan	45
Gambar 3. 22 Flowchart pengambilan data curah hujan.....	48
Gambar 3. 23 Desain Pengelolaan Data.....	50
Gambar 3. 24 Desain Model Prediksi	52
Gambar 4. 1 Instalasi App Prediction Oil di Mobile	61

Gambar 4. 2 Halaman Login (Petugas Lapangan)	62
Gambar 4. 3 Halaman Beranda (Petugas Lapangan)	63
Gambar 4. 4 Halaman Login (Admin)	64
Gambar 4. 5 Halaman Dashboard (Admin)	65
Gambar 4. 6 Halaman Afdeling (Admin)	65
Gambar 4. 7 Halaman Dataset Sistem (Admin).....	66
Gambar 4. 8 Halaman Prediksi (Admin).....	67
Gambar 4. 9 Halaman Hasil Prediksi (Admin)	67
Gambar 4. 10 Halaman Laporan (Manager)	68
Gambar 4. 11 Google Earth Engine CHIRPS Daily	69
Gambar 4. 12 Grafik chart data curah hujan	70
Gambar 4. 13 Hasil Cleaning Data	74
Gambar 4. 14 Hasil Normalisasi Menggunakan MinMaxScaller	75
Gambar 4. 15 Layer Model Yang digunakan.....	76
Gambar 4. 16 Grafik Hasil Evaluasi Training	83
Gambar 4. 17 Grafik Hasil Evaluasi Testing Model.....	84
Gambar 4. 18 Perbandingan evaluasi testing dan training	85
Gambar 4. 19 Perbandingan data aktual, prediksi, dan selisih.....	87
Gambar 4. 20 Perbandingan nilai MAE dan rata-rata nilai aktual	87
Gambar 4. 21 Perbandingan data aktual, prediksi, dan selisih.....	89
Gambar 4. 22 Perbandingan nilai RMSE dan rata-rata nilai aktual	89

DAFTAR TABEL

Tabel 2. 1 State of The Art.....	6
Tabel 3. 1 Analisis Kebutuhan Data	21
Tabel 3. 2 Definisi Aktor	24
Tabel 3. 7 Definisi Use Case.....	25
Tabel 3. 1 Data <i>Real</i> dan <i>Dummy</i>	47
Tabel 3. 2 Skenario MAE.....	57
Tabel 3. 3 Skenario RMSE.....	58
Tabel 3. 4 Skenario R ² Score	59
Tabel 4. 1 Sampel data curah hujan harian	70
Tabel 4. 2 Sampel data curah hujan bulanan.....	71
Tabel 4. 3 Data Pemupukan	72
Tabel 4. 4 Data Hasil Produksi	73
Tabel 4. 8 Pengujian Halaman Login Admin.....	77
Tabel 4. 9 Pengujian Halaman Login Petugas Lapangan	78
Tabel 4. 10 Pengujian Halaman Prediksi Admin	80
Tabel 4. 11 Pengujian Input Data Pemupukan dan Hasil Produksi Petugas Lapangan	81
Tabel 4. 12 Pengujian Logout	82
Tabel 4. 5 Nilai Evaluasi Testing MAE	86
Tabel 4. 6 Nilai Evaluasi Testing RMSE	88
Tabel 4. 7 Nilai Evluasi Testing RMSE.....	90

DAFTAR LAMPIRAN

Lampiran 1. <i>Script</i> Pembuatan Dataset <i>Dummy</i>	97
Lampiran 2. <i>Script</i> Pengambilan Data Curah Hujan.....	99
Lampiran 3. Hasil Perhitungan MAE.....	100
Lampiran 4. Hasil Perhitungan RMSE.....	102
Lampiran 5. Hasil Perhitungan <i>R2 Score</i>	104

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Tanaman kelapa sawit (*Elaeis guineensis* Jacq.) telah menjadi salah satu komoditas strategis di Indonesia sejak diperkenalkan oleh Belanda pada tahun 1848 di Kebun Raya Bogor [1]. Sebagai produsen minyak sawit mentah (*Crude Palm Oil/CPO*) terbesar di dunia, Indonesia menguasai lebih dari 50% pasar global, dengan ekspor yang terus meningkat sejak awal 2000-an [2]. Pada tahun 2015, Indonesia menghasilkan sekitar 31,5 juta ton CPO, menyumbang pendapatan devisa signifikan dan menciptakan lapangan kerja bagi jutaan orang, terutama di wilayah pedesaan [3].

Meskipun memiliki peran penting, industri kelapa sawit menghadapi tantangan operasional yang signifikan, terutama dalam pengelolaan data produksi. Selain itu, tantangan seperti ketidakstabilan harga global dan variabilitas hasil panen akibat faktor musiman memperumit pengelolaan operasional [4]. Lebih lanjut, belum ada prediksi produksi minyak sawit dalam beberapa tahun ke depan, prediksi ini penting bagi perusahaan untuk memaksimalkan kinerjanya. Sementara itu, pengelompokan dan prediksi dapat menyarankan arah kebijakan yang cepat untuk menstabilkan produksi minyak sawit dan meningkatkan kemampuannya setiap tahun [5].

Untuk mengatasi tantangan tersebut, diperlukan pendekatan berbasis teknologi yang dapat meningkatkan akurasi prediksi produksi. *Long Short-Term Memory* (LSTM), sebuah modifikasi dari *Recurrent Neural Network* (RNN), telah terbukti efektif dalam memproses data deret waktu untuk memprediksi hasil panen kelapa sawit [6]. Selain LSTM, metode prediksi alternatif seperti ARIMA juga telah digunakan secara efektif untuk meramalkan harga minyak sawit berdasarkan data historis. *Random Forest* telah diterapkan dalam prediksi hasil panen kelapa sawit dengan mempertimbangkan faktor cuaca dan kelembaban tanah, menunjukkan performa yang kompetitif dibandingkan model lain, tetapi bisa menghabiskan banyak waktu dalam menangkap pola yang terlalu kompleks

[7]. *Support Vector Regression* (SVR) telah dimanfaatkan untuk memprediksi harga CPO melalui pendekatan *multivariate time series*, dengan perbandingan terhadap model *machine learning* lainnya [8].

Model LSTM dapat mencapai akurasi hingga 93,7% dengan *Mean Absolute Error* (MAE) yang rendah dalam memprediksi hasil panen berdasarkan data petani dari Januari 2023 hingga Januari 2024. Penelitian ini menyoroti kemampuan LSTM untuk menangani pola kompleks yang dipengaruhi oleh faktor lingkungan dan manajemen perawatan tanaman [9]. Pemilihan metode LSTM dalam penelitian ini didasarkan pada kemampuannya dalam mempertahankan pola kompleks yang dipengaruhi oleh perubahan iklim dan faktor-faktor lainnya, melalui mekanisme sel memori serta gerbang (*input*, *output*, dan *forget*) [10].

Penelitian ini bertujuan untuk mengembangkan model prediksi hasil produksi kelapa sawit menggunakan metode LSTM, dengan fokus pada data deret waktu (*time series*) terkait faktor lingkungan dan manajemen perawatan tanaman, seperti curah hujan dan pemupukan. Diharapkan bahwa model LSTM yang dikembangkan dapat menghasilkan prediksi yang akurat mengenai hasil produksi kelapa sawit di PTPN IV REGIONAL 6 KSO menggunakan algoritma *Long Short-term Memory* (LSTM).

1.2 Rumusan Masalah

Berdasarkan latar belakang dan permasalahan di atas, maka dirumuskan masalah sebagai berikut:

1. Bagaimana performa model *Long Short-Term Memory* (LSTM) dalam memprediksi hasil produksi kelapa sawit?

1.3 Batasan Masalah

Mengingat banyaknya pembahasan yang ada dalam penelitian ini, maka perlu batasan yang jelas mengenai hal-hal yang dibuat dan diselesaikan. Adapun batasan masalah dalam penelitian ini antara lain:

1. Penelitian ini fokus pada implementasi dan melihat performa model *Long Short-Term Memory* (LSTM) secara spesifik, meskipun tinjauan pustaka menyajikan perbandingan dengan metode lain sebagai konteks.
2. Data yang dianalisis adalah Data *Time Series* dari wilayah unit Kebun Lama, sehingga hasil penelitian mungkin tidak sepenuhnya dapat digeneralisasikan untuk wilayah atau unit lain dengan kondisi yang berbeda.

1.4 Tujuan Penelitian

Berdasarkan rumusan masalah di atas, maka tujuan dilakukan penelitian ini adalah:

1. Mengimplementasikan model prediksi *Long Short-Term Memory* (LSTM) yang akurat untuk memprediksi hasil produksi kelapa sawit.

1.5 Manfaat Penelitian

Adapun manfaat dari penelitian ini adalah sebagai berikut:

1. Memberikan kontribusi ilmiah sebagai referensi bagi penelitian selanjutnya dalam penerapan model *Long Short-Term Memory* LSTM pada komoditas pertanian kelapa sawit.

1.6 Sistematika Penulisan

Sistematika penulisan skripsi ini disusun untuk memberikan gambaran singkat mengenai alur dan ruang lingkup penelitian yang dilakukan. Adapun rinciannya disajikan sebagai berikut.

BAB I PENDAHULUAN

Bab ini menjelaskan latar belakang masalah, rumusan masalah, batasan masalah, tujuan penelitian, dan manfaat penelitian. Bab ini memberikan dasar dan alasan mengapa penelitian ini dilakukan.

BAB II TINJAUAN PUSTAKA

Bab ini berisi teori-teori yang mendukung penelitian, seperti penjelasan tentang kelapa sawit, machine learning, *Long Short-Term Memory* (LSTM), serta penelitian terdahulu yang relevan sebagai acuan dan pembanding.

BAB III METODOLIGI PENELITIAN

Bab ini menguraikan metode yang digunakan dalam penelitian, termasuk pengumpulan data, *preprocessing* data, pembangunan model LSTM, serta teknik evaluasi yang digunakan untuk mengukur kinerja model.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil dari proses pelatihan model dan evaluasi, termasuk performa model dalam bentuk metrik MAE, RMSE, dan *R2 Score*.

BAB V PENUTUP

Bab ini berisi kesimpulan dari hasil penelitian yang telah dilakukan serta saran yang dapat diberikan untuk pengembangan penelitian atau sistem di masa mendatang.

BAB II

TINJAUAN PUSTAKA

1.1 *State of The Art*

State of the Art merupakan bagian fundamental dalam setiap penelitian ilmiah. Tujuannya adalah untuk mengidentifikasi, mengevaluasi, dan merangkum hasil-hasil penelitian yang telah dipublikasikan oleh para akademisi dan peneliti lain yang relevan dengan topik yang sedang diteliti. Proses ini bukan hanya sekadar mengumpulkan daftar referensi, melainkan sebuah analisis kritis untuk memahami perkembangan ilmu pengetahuan di bidang tersebut hingga saat ini. Melalui tinjauan ini, sebuah penelitian dapat menempatkan posisinya secara akurat, mengidentifikasi celah penelitian (*research gap*), dan menunjukkan orisinalitas serta kontribusi keilmuan yang ditawarkan.

Dalam konteks penelitian ini, tinjauan pustaka difokuskan pada karya-karya yang membahas model prediksi dalam sektor pertanian, khususnya yang memanfaatkan teknik *machine learning* dan *deep learning*. Oleh karena itu, penelitian ini memilih untuk mengeksplorasi metode *Long Short-Term Memory* (LSTM) yang merupakan varian dari jaringan saraf berulang (*Recurrent Neural Network* - RNN) yang secara khusus dirancang untuk menangani data deret waktu. *State of The Art* ini akan membandingkan pendekatan yang digunakan dalam penelitian ini dengan penelitian-penelitian sebelumnya, dengan penekanan pada metode, dan hasil yang diperoleh. Perbandingan ini akan memberikan dasar kuat mengapa metode LSTM dianggap lebih relevan dan menjanjikan untuk memecahkan masalah prediksi hasil produksi kelapa sawit yang kompleks. Ringkasan dari *State of The Art* yang menjadi acuan dalam penelitian ini disajikan pada Tabel 2.1.

Tabel 2. 1 *State of The Art*

No	Penulis /Tahun	Judul Artikel	Metode yang digunakan	Hasil yang diperoleh	Persamaan	Perbedaan
1	Budi Yanto, Erni Rouza , Edi Saputra / 2019	Penerapan Metode Inferensi Fuzzy Takagi Sugeno-Kang Untuk Prediksi Hasil Panen Kelapa Sawit	Inferensi <i>Fuzzy</i> Takagi Sugeno-Kang	Mengetahui hasil panen berikutnya pada petani Kelapa sawit dengan perhitungan Fuzzy Takagi Sugeno Kang (TSK).	Menekankan penggunaan metode atau algoritma canggih untuk analisis data, guna menghasilkan prediksi akurat dalam sektor perkebunan kelapa sawit.	Menggunakan inferensi Fuzzy Takagi Sugeno-Kang untuk menangani ketidakpastian dengan logika fuzzy, sedangkan penelitian pada tugas akhir ini memakai algoritma <i>Long Short-Term Memory (LSTM)</i> untuk klasifikasi dan pemilahan data.
2	Irma Hakim, Asdi, Teuku Afriliansya	Implementasi Algoritma Komputasi Linear Regression untuk Optimasi Prediksi Hasil Pertanian	Metode <i>Linear Regression</i>	Penggunaan metode <i>Linear Regression</i> yang berhasil menunjukkan akurasi tinggi dengan nilai MSE sebesar 329.509% dan nilai R^2 <i>Score</i> sebesar 0.349 menunjukkan bahwa model dapat menjelaskan sekitar 34.9% variabelitas data target.	Meningkatkan akurasi prediksi hasil produksi atau panen berdasarkan Data Time Series.	Menggunakan algoritma Linear Regression.

3	Niken Putri Setyadi	Penerapan Data Mining Untuk Prediksi Hasil Produksi Karet Menggunakan Algoritma Decision Tree C4.5	<i>Decision Tree C4.5</i>	Produksi yang tercapai sebanyak 709 dan produksi yang tidak tercapai sebanyak 192.	Menggunakan variabel lingkungan dan manajemen/perawatan sebagai faktor utama dalam memprediksi hasil produksi.	Menggunakan Metode Decision Tree C4.5
4	Yesi Pitaloka Anggriani, AlfisArif, Febriansyah	Implementasi Algoritma K-Means Clustering dalam Menentukan Blok Tanaman Sawit Produktif Pada Pt Arta Prigel	<i>K-Means Clustering</i>	Proses clustering data dalam menentukan blok produktif terbentuk menjadi 3 cluster yaitu cluster_0 dengan keterangan Cukup Produktif, cluster_1 dengan keterangan Produktif, dan cluster_2 dengan keterangan Tidak Produktif.	Berfokus pada tanaman kelapa sawit sebagai komoditas utama.	Menggunakan algoritma <i>K-Means Clustering</i> . Sedangkan penelitian tugas akhir menggunakan algoritma <i>Long Short-Term Memory (LSTM)</i>
5	Syukri Habibi Nasution, Chairani Hanum, Jasmani Ginting	Pertumbuhan Bibit Kelapa Sawit (<i>Elaeis Guineensis</i> Jacq.) Pada Berbagai Perbandingan Media Tanam Solid Decanter Dan Tandan Kosong Kelapa Sawit Pada Sistem Single Stage	Rancangan Acak Kelompok Nonfaktorial (RAK Nonfaktorial)	Perlakuan media tanam berpengaruh nyata terhadap semua peubah amatan kecuali tinggi bibit 6, 8, dan 10 MST.	Memiliki hubungan dengan aspek lingkungan, baik dari segi penggunaan material sisa kelapa sawit (penelitian[4]) maupun faktor lingkungan yang memengaruhi hasil produksi (penelitian tugas akhir).	Fokus pada pengaruh perbandingan media tanam (solid decanter dan tandan kosong kelapa sawit) terhadap pertumbuhan bibit kelapa sawit. Sedangkan penelitian tugas akhir Fokus pada memprediksi hasil produksi kelapa sawit berdasarkan faktor lingkungan dan perawatan.

6	Masykur	Pengembangan Industri Kelapa Sawit Sebagai Penghasil Energi Bahan Bakar Alternatif dan Mengurangi Pemanasan Global	Metode deskripsi dengan pendekatan komprehensif integral.	-	Berfokus pada kelapa sawit sebagai elemen utama penelitian.	Lebih menekankan potensi kelapa sawit sebagai bahan energi alternatif untuk mengurangi pemanasan global. Sedangkan penelitian tugas akhir Menitik beratkan pada analisis prediktif hasil produksi kelapa sawit berdasarkan faktor lingkungan dan perawatan.
---	---------	--	---	---	---	---

1.2 Kelapa Sawit

Kelapa sawit (*Elaeis guineensis* Jacq) adalah tanaman tropis dari golongan plasma yang tergolong tanaman tahunan. Asalnya dari Afrika Barat, namun tanaman ini tumbuh dengan baik di negara-negara seperti Indonesia, Malaysia, Thailand, dan Papua Nugini. Kelapa sawit memiliki peran penting dalam pembangunan nasional karena mampu menciptakan banyak lapangan kerja dan menjadi salah satu sumber devisa negara. Budidaya kelapa sawit secara komersial di Indonesia dimulai pada tahun 1991. Tokoh yang pertama kali mengembangkan perkebunan kelapa sawit di Indonesia adalah Adrian Hallet, seorang warga negara Belgia yang memperoleh pengetahuan tentang tanaman ini dari Afrika (Fauzi, 2009:5)[11].

Minyak kelapa sawit yang digunakan sebagai bahan pangan memiliki dua aspek utama dalam penilaiannya. Aspek pertama mencakup kandungan serta mutu asam lemak, tingkat kelembapan, dan jumlah kotoran yang terkandung. Sementara itu, aspek kedua meliputi cita rasa, aroma, kejernihan, serta tingkat kemurnian minyak. Minyak ini diekstrak dari buah kelapa sawit, di mana satu tandan buah bisa mencapai berat 40 hingga 50 kilogram. Dari 100 kilogram buah kelapa sawit, dapat diperoleh sekitar 20 kilogram minyak. Satu hektar lahan kelapa sawit bahkan dapat menghasilkan sekitar 5.000 kilogram atau hampir 6.000 liter minyak mentah (Journey to Forever, 2010).

Kelapa sawit merupakan komoditas andalan Indonesia yang perkembangannya sangat pesat. Secara umum, limbah dari pabrik kelapa sawit terdiri atas tiga jenis, yaitu limbah cair, padat, dan gas. Limbah padat yang dihasilkan dari proses pengolahan meliputi tandan kosong kelapa sawit (TKKS), cangkang atau tempurung, serabut atau serat, sludge atau lumpur sawit, dan bungkil [12].


Meningkatnya permintaan akan pupuk organik membuka peluang untuk memanfaatkan tandan kosong kelapa sawit (TKKS) sebagai kompos secara lebih ekonomis. Melalui proses dekomposisi, TKKS dapat diubah menjadi pupuk yang mengandung unsur hara penting seperti nitrogen (N), fosfor (P), kalium (K), dan magnesium (Mg) yang dibutuhkan oleh tanaman. Pengolahan TKKS segar

menjadi kompos memiliki dua fungsi utama: sebagai solusi pengelolaan limbah padat dan cair dari TKKS, serta sebagai sumber bahan organik yang bernilai ekonomi bagi tanaman.

Solid merupakan limbah padat yang dihasilkan dari proses pengolahan minyak kelapa sawit mentah. Di wilayah Sumatera, limbah ini sering disebut sebagai lumpur sawit, meskipun sebenarnya solid telah dipisahkan dari bagian cairnya sehingga tergolong sebagai limbah padat. Dalam produksi CPO (*Crude Palm Oil*), dihasilkan dua jenis limbah, yaitu limbah cair dan limbah padat. Hingga kini, limbah solid sawit belum dimanfaatkan secara optimal oleh pabrik dan umumnya hanya dibuang, yang berpotensi mencemari lingkungan. Proses pembuangannya pun membutuhkan biaya besar karena harus membuat lubang penampungan besar. Oleh karena itu, jika limbah solid ini bisa dimanfaatkan secara luas, tentu akan memberikan keuntungan besar bagi pihak pabrik [13].

1.3 *Machine Learning*

Machine learning merupakan penerapan algoritma matematika dan program komputer yang memungkinkan sistem untuk belajar dari data dan menghasilkan prediksi di masa depan (Goldberg & Holland, 1988). Proses pembelajaran ini mencakup dua tahap utama, yaitu pelatihan (*training*) dan pengujian (*testing*), yang bertujuan untuk membentuk kecerdasan sistem (Huang, Zhu, & Siew, 2006). Secara umum, bidang *machine learning* menyoroti bagaimana sebuah program komputer dapat berkembang secara otomatis berdasarkan pengalaman yang diperoleh (Mitchell, 1997). Saat ini, *machine learning* diklasifikasikan ke dalam tiga jenis utama, yaitu *Supervised Learning*, *Unsupervised Learning*, dan *Reinforcement Learning* (Somvanshi & Chavan, 2016). Hubungan antara *artificial intelligence* dan *machine learning* dapat dilihat pada Gambar 2.1 [14].



Gambar 2. 1 Skema *Artificial Intelligence* (AI) dan *Machine Learning*

Menggambarkan hubungan antara kecerdasan buatan (*Artificial Intelligence*) dan pembelajaran mesin (*Machine Learning*), serta tiga cabang utamanya. Diagram tersebut menjelaskan bahwa *machine learning* adalah sub-bidang dari *artificial intelligence* yang berfokus pada pengembangan algoritma agar mesin dapat belajar dan meningkatkan kinerjanya dari pengalaman. Cabang-cabang utama dari *machine learning*, yang disoroti dalam diagram meliputi *supervised learning* (pembelajaran terawasi) di mana model dilatih menggunakan data yang sudah berlabel, *unsupervised learning* (pembelajaran tak terawasi) yang mencari pola dalam data tanpa label, dan *reinforcement learning* (pembelajaran penguatan) di mana model belajar melalui interaksi dengan lingkungannya untuk memaksimalkan *rewards*.

1.4 *Recurrent Neural Network (RNN)*


RNN (*Recurrent Neural Network*) merupakan salah satu bentuk arsitektur dari jaringan saraf tiruan (ANN) yang dirancang khusus untuk menangani data berurutan, seperti teks, suara, atau data *time-series*. Keunggulan utama RNN terletak pada kemampuannya menyimpan informasi dari langkah sebelumnya dan memanfaatkannya dalam menghasilkan output pada langkah saat ini (Smagulova & James, 2019).

RNN bekerja dengan mengolah data masukan sambil mempertimbangkan informasi yang telah diterima sebelumnya. Hasil atau keputusan yang dihasilkan dari suatu input akan dipengaruhi oleh pengetahuan yang telah tersimpan dari input-input sebelumnya. Seiring waktu, mekanisme kerja RNN terus disempurnakan melalui berbagai pengembangan, salah satunya adalah dengan menggunakan metode LSTM (*Long Short-Term Memory*) (RNN (Recurrent Neural Network): Cara Kerja Dan Implementasi - Algoritma, n.d.).

1.5 *Deep Learning*

Semenjak tahun 1950-an, salah satu cabang dari *Artificial Intelligence* (AI) yang disebut dengan *Machine Learning* telah berkembang cukup pesat dengan implementasi di beberapa bidang. *Neural Network* adalah salah satu implementasi dari *Machine Learning*, sedangkan *Deep Learning* merupakan salah satu implementasi dari *Neural Network*. *Deep Learning*, yang mulai populer digunakan sejak tahun 2006, menggunakan mekanisme *deep architecture of learning* atau pendekatan *hierarchical learning*. *Learning* atau pembelajaran dalam hal ini adalah sebuah prosedur yang berisi proses estimasi parameter-parameter suatu model sehingga model yang dikembangkan (*algoritme*) dapat menyelesaikan suatu tugas atau permasalahan tertentu. *Deep Learning* menggunakan beberapa lapisan (*layers*) di antara lapisan masukan (*input layer*) dan lapisan keluaran (*output layer*). Arsitektur tersebut dapat digunakan untuk melakukan pemrosesan *nonlinier* dengan beberapa tahap yang hasilnya dapat digunakan untuk *feature learning* dan klasifikasi pola. Jumlah lapisan dalam *deep learning* yang bervariasi dapat digunakan untuk melakukan abstraksi dengan tingkat yang berbeda-beda. *Deep Learning* juga dapat dideskripsikan sebagai sebuah kelas dalam algoritma *machine learning* yang menggunakan beberapa lapisan pemrosesan *nonlinier* yang disusun secara *cascade* untuk ekstraksi fitur (*feature extraction*) dan *transformation*. Setiap lapisan menggunakan keluaran dari lapisan sebelumnya sebagai masukannya. Algoritma yang digunakan dapat bertipe *supervised* dan *unsupervised* serta implementasinya dapat digunakan

sebagai *pattern analysis (unsupervised)* dan klasifikasi (*supervised*)[17]. Hirarki *artificial intelegence* yang mencakup *deep learning* bisa dilihat pada Gambar 2.2.




Gambar 2. 2 Diagram *Venn* Hirarki *Artificial Intelegence*

Diagram *Venn* yang menunjukkan hierarki dan hubungan antara berbagai konsep di bidang kecerdasan buatan (AI). Pada dasarnya, AI adalah bidang yang sangat luas, di mana di dalamnya terdapat *Machine Learning* (ML), yaitu salah satu metode AI yang fokus pada pembelajaran dari data. Di dalam ML, terdapat konsep yang terinspirasi dari otak manusia (*Brain Inspired*), yang salah satunya adalah *Neural Network* (NN), sebuah model komputasi yang meniru cara kerja otak. Terakhir, *Deep Learning* (DL) adalah sub-bidang dari *Neural Network* (NN) yang memanfaatkan banyak lapisan pemrosesan untuk menganalisis data, menjadikannya bagian inti dari NN dan juga AI secara keseluruhan.

1.6 Long Short-Term Memory

LSTM (*Long Short-Term Memory*) adalah salah satu bentuk pengembangan dari arsitektur RNN (*Recurrent Neural Network*). Model ini sangat efektif digunakan untuk tugas klasifikasi, pemrosesan, dan prediksi data deret waktu

(*time series*), karena mampu menangani jeda waktu yang tidak menentu antar peristiwa penting dalam urutan data tersebut [18]. Metode LSTM memiliki struktur yang menyerupai arsitektur RNN, namun perbedaannya terletak pada mekanisme *hidden state*-nya. Pada LSTM, proses ini melibatkan empat gerbang utama, yaitu *forget gate*, *input gate*, *cell state*, dan *output gate* [19]. Ilustrasi dari proses metode LSTM dapat dilihat pada Gambar 2.3 berikut.



Gambar 2. 3 Alur Proses *LSTM*

Setiap gerbang dalam jaringan menggunakan input X_t dan *hidden state* dari waktu sebelumnya h_{t-1} , dengan bobot dan bias yang sudah ditetapkan sejak awal. Gerbang pertama yang dilewati oleh input adalah *forget gate*, yang bekerja menggunakan fungsi aktivasi sigmoid. Nilai dari *forget gate* dihitung berdasarkan persamaan (2.1).

$$f_t = \sigma(W_f \cdot [h_{t-1}, X_t] + b_f) \quad (2.1)$$

Dalam hal ini, f_t mewakili *forget gate*, σ merupakan fungsi aktivasi sigmoid, W_f adalah bobot yang digunakan pada *forget gate*, h_{t-1} menunjukkan nilai *hidden state* dari langkah waktu sebelumnya, X_t adalah input saat ini, dan b_f merupakan bias yang terkait dengan *forget gate*.

Langkah kedua dalam pengolahan *hidden state* adalah menghitung nilai dari *input gate*. Proses ini melibatkan input saat ini X_t , bobot W_i , bias B_i , serta *hidden state* dari waktu sebelumnya h_{t-1} . Nilai *input gate* dihitung menggunakan fungsi aktivasi *sigmoid* σ , sesuai dengan persamaan (2).

$$i_t = \sigma (W_i \cdot [h_{t-1}, X_t] + b_i) \quad (2.2)$$

Di dalam *input gate*, terdapat satu tahapan tambahan, yaitu perhitungan nilai kandidat *cell state* baru. Nilai kandidat ini, yang dilambangkan sebagai C_t , dihitung menggunakan fungsi aktivasi *tanh*, sebagaimana ditunjukkan pada persamaan (3).

$$\hat{C}_t = \tanh(W_c \cdot [s_{t-1}, x_t] + b_c) \quad (2.3)$$

Setelah didapatkan nilai *forget gate*, *input gate*, dan kandidat *cell state* baru, maka nilai, *cell state* C_t dapat dicari dengan menjumlahkan hasil perkalian *forget gate* f_t dan *cell state* sebelumnya C_{t-1} dengan hasil perkalian *input gate* C_t dengan kandidat *cell state* baru C_t menggunakan persamaan

Setelah nilai *forget gate*, *input gate*, dan kandidat *cell state* baru diperoleh, maka nilai *cell state* saat ini C_t dapat dihitung. Perhitungannya dilakukan dengan menjumlahkan hasil perkalian antara *forget gate* f_t dan *cell state* sebelumnya C_{t-1} , dengan hasil perkalian antara *input gate* C_t dan kandidat *cell state* baru C_t , sesuai dengan persamaan (4).

$$C_t = f_t * C_{t-1} + i_t * \hat{C}_t \quad (2.4)$$

Tahapan berikutnya adalah menghitung *output gate*, yang memanfaatkan fungsi aktivasi sigmoid. Nilai dari *output gate* berperan dalam membentuk *hidden state* yang baru dengan mempertimbangkan *cell state* saat ini. Perhitungan *output gate* dilakukan menggunakan persamaan (5).

$$o_t = \sigma (W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.5)$$

Nilai *output gate* yang didapatkan akan digunakan sebagai keluaran *hidden state* menggunakan fungsi *tanh*. Nilai *hidden state* diperoleh dengan mengalikan nilai *output gate* dan *cell state* yang telah melalui proses fungsi *tanh*, seperti terlihat pada persamaan (6).

$$h_t = o_t * \tanh(C_t) \quad (2.6)$$

Nilai *hidden state* dihasilkan dengan cara mengalikan keluaran dari *output gate* dengan hasil aktivasi *tanh* dari *cell state*. Proses ini mengontrol informasi apa yang akan diteruskan keluar dari sel LSTM ke jaringan berikutnya atau ke langkah waktu selanjutnya.

1.7 *Progressive Web App* (PWA)

Progressive Web Apps (PWA) merupakan inovasi teknologi yang diperkenalkan oleh *Google* pada Juni 2015 untuk menjembatani keterbatasan antara aplikasi *native* dan *browser* seluler. PWA memanfaatkan teknologi *website* modern, yang mencakup serangkaian konsep desain, *API web*, dan fitur-fitur lainnya, guna memberikan pengalaman pengguna yang menyerupai aplikasi *native*. [20].

Menggunakan konsep PWA akan membuat pengguna bisa menjalankan aplikasi di berbagai *platform* seperti *website*, *desktop*, dan *platform mobile* atau Android, PWA sendiri memiliki berbagai keunggulan seperti:

1. PWA memiliki kemampuan menyerupai aplikasi *native* seperti pada perangkat Android, namun pembuatannya tidak memerlukan perangkat keras dengan spesifikasi tinggi.
2. Penggunaan PWA dapat mempercepat proses pengembangan situs *web* sekaligus mengurangi beban pada server.


3. Berbeda dengan situs *web* konvensional yang memerlukan koneksi internet, PWA tetap dapat diakses meskipun dalam kondisi *offline*.
4. Banyak perusahaan besar seperti *Twitter*, *Facebook*, *Bukalapak*, *Tokopedia*, dan lainnya telah mengadopsi PWA dalam layanannya.

Proses instalasi PWA sangat mudah, hanya dengan mengakses *website* PWA yang diinginkan kemudian memilih opsi install, maka *icon* aplikasi PWA akan muncul di *home screen* [21].

1.8 Prototyping

Prototyping adalah salah satu metode dalam pengembangan sistem yang sering digunakan, karena memungkinkan adanya interaksi langsung antara pengembang dan pengguna selama proses pembuatan. Dengan pendekatan ini, pengembang dapat dengan lebih mudah merancang dan memvisualisasikan perangkat lunak yang akan dikembangkan [22].

Metode ini bertujuan untuk menyempurnakan model hingga menjadi perangkat lunak akhir. Dengan pendekatan ini, proses pengembangan dapat dilakukan lebih cepat dan dengan biaya yang lebih efisien. Dalam penerapannya, metode prototyping terdiri dari beberapa tahapan yang harus dilalui selama proses pengembangan perangkat lunak. Alur proses *prototyping* bisa dilihat pada Gambar 2.4.



Gambar 2. 4 Alur proses *Prototyping*

Berikut adalah tahap-tahap pengembangan perangkat lunak menggunakan metode *prototype*.

1. Identifikasi Kebutuhan

Pada tahap awal, pengembang mengumpulkan dan menganalisis seluruh kebutuhan sistem dan perangkat lunak yang akan dibangun.

2. Pembuatan Prototipe

Merancang model awal sistem yang menekankan alur kerja aplikasi agar dapat dipahami oleh pengguna.

3. Penilaian Prototipe

Prototipe yang telah dibuat dievaluasi untuk memastikan apakah sudah sesuai dengan kebutuhan dan ekspektasi pengguna.

4. Implementasi Sistem

Jika prototipe mendapatkan persetujuan, maka selanjutnya akan dikembangkan ke dalam bentuk kode menggunakan bahasa pemrograman yang sesuai.

5. Pengujian Perangkat Lunak

Setelah pengembangan selesai, sistem harus diuji untuk memastikan fungsionalitasnya. Metode pengujian yang umum digunakan termasuk White Box Testing, Black Box Testing, dan metode lainnya.

6. Tinjauan Ulang Sistem

Pengguna menilai apakah sistem telah sesuai dengan yang dibutuhkan. Jika belum, proses pengkodean dan pengujian diulangi hingga sistem memenuhi harapan.

7. Penerapan Sistem

Setelah semua tahapan selesai dan sistem dinyatakan layak, perangkat lunak siap untuk digunakan secara resmi [23].

1.9 MAE (*Mean Absoulute Error*)

Mean Absolute Error (MAE) adalah rata-rata dari selisih mutlak antara nilai aktual dan nilai hasil prediksi model. Semakin kecil nilai MAE, maka semakin

tinggi tingkat akurasi model dalam memperkirakan nilai yang sebenarnya [24]. Nilai dari MAE dihitung berdasarkan persamaan (2.7).

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i| \quad (2.7)$$

Keterangan:

$\hat{Y}_i$: Nilai Prediksi

Y_i : Nilai aktual / Nilai sebenarnya

n : Jumlah Data

1.10 RMSE (*Root Mean Square Error*)

Root Mean Square Error (RMSE) adalah salah satu metode alternatif yang digunakan untuk menilai keakuratan suatu model peramalan. Metode ini menghitung rata-rata dari kuadrat selisih antara nilai prediksi dan nilai aktual. RMSE dikenal sebagai teknik evaluasi yang sederhana untuk diterapkan dan telah banyak dimanfaatkan dalam berbagai penelitian yang berfokus pada prediksi atau peramalan [25]. Nilai dari RMSE dihitung berdasarkan persamaan (2.8).

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (\tilde{y}_i - y_i)^2} \quad (2.8)$$

Keterangan:

$\tilde{y}_i$: Nilai Prediksi

y_i : Nilai *actual* / Nilai sebenarnya

n : Jumlah Data

1.11 *R2 Score*

R2 Score adalah ukuran mengenai seberapa dekat nilai prediksi dari suatu model cocok dengan nilai yang diamati. Nilai *R2 Score* ideal suatu model adalah 1 yang menunjukkan bahwa model tersebut dapat menjelaskan seluruh variabilitas pada kelas sasaran [26]. Nilai *R2 Score* berada dalam rentang antara 0 hingga 1, di

mana nilai 0 menandakan bahwa model tidak mampu mengungguli rata-rata dari nilai target. Sebaliknya, nilai 1 menunjukkan bahwa model mampu menjelaskan hubungan antara variabel independen dan dependen secara sempurna. Nilai dari RMSE dihitung berdasarkan persamaan (2.9).

$$R^2 \text{ score} = 1 - \frac{\sum_{i=1}^m (y_i - \hat{y}_i)^2}{\sum_{i=1}^m (y_i - \mu_y)^2} \quad (2.9)$$

Keterangan:

$\hat{y}_i$: Nilai prediksi

y_i : Nilai aktual / Nilai sebenarnya

$\bar{y}_i$: Nilai rata-rata aktual

n : Jumlah data

$R^2 \text{ score}$ juga dapat didefinisikan sebagai jumlah bagi *Residual Sum of Squares (RSS)* dengan *Total Sum of Squares (TSS)*.

BAB III

METODE PENELITIAN

3.1 Rancangan Sistem

Teknik yang digunakan dalam Perancangan sistem ini adalah *Unified Modeling Language (UML)*, sebagai metode pemodelan untuk memvisualisasikan perancangan sistem. UML digunakan untuk menggambarkan interaksi antara pengguna dan aplikasi dengan menggunakan 2 jenis diagram yaitu *Use Case Diagram* dan *Activity Diagram*.

3.2.1 Analisis Kebutuhan Data

Analisis kebutuhan data adalah proses untuk mengidentifikasi, menganalisis, dan memvalidasi kebutuhan data yang digunakan oleh sebuah aplikasi. Berikut ini adalah hal-hal yang harus diperhatikan untuk memenuhi kebutuhan data dari sistem ini dapat dilihat pada Tabel 3.1.

Tabel 3. 1 Analisis Kebutuhan Data

No	Jenis Data	Deskripsi
1	Data Pengguna	Informasi tentang akun pengguna seperti username, password, dan peran.
2	Dataset <i>Time Series</i>	Gabungan data lingkungan, perawatan, dan hasil produksi <i>time series</i> .
3	Data Real-time	Data mencakup faktor lingkungan, perawatan, dan hasil produksi yang telah dikumpulkan setelah analisis waktu nyata.
4	Hasil Prediksi	Output model prediksi yang berupa estimasi jumlah produksi berdasarkan inputan Data Time Series.
5	Laporan Produksi	File yang berisi hasil prediksi dalam bentuk tabel, grafik, atau angka.

3.2.2 Analisis Kebutuhan Fungsional

Kebutuhan fungsional adalah kebutuhan yang berdasarkan proses yang mampu disediakan oleh sistem dan mencakup kebutuhan dasar pengguna tersebut berupa fitur, layanan dan fungsi. Kebutuhan ini menentukan bagaimana sistem seharusnya berperilaku dalam merespons input dari pengguna maupun dari lingkungan. Sedangkan kebutuhan non fungsional merupakan sekumpulan batasan, karakteristik, dan properti pada sistem, baik dalam pengembangan maupun operasional. Kebutuhan ini mencakup aspek seperti performa, keandalan, keamanan, skalabilitas, dan kemudahan penggunaan. Berikut adalah kebutuhan fungsional yang akan diterapkan pada sistem ini:

a. User

User terbagi menjadi 3 bagian yaitu asisten kepala, *admin*, dan petugas lapangan:

1. Asisten Kepala

- Asisten Kepala dapat melakukan login menggunakan akun yang sudah terdaftar.
- Asisten Kepala dapat melihat hasil prediksi
- Asisten Kepala dapat mengunduh laporan.

2. Admin

- *Admin* bisa melakukan login dengan akun yang sudah terdaftar.
- *Admin* dapat menambah, mengubah, dan menghapus *Data Time Series*, termasuk data terkait faktor lingkungan dan perawatan.
- *Admin* bisa menambah, mengubah, dan menghapus data pengguna.
- *Admin* dapat menginput *Data Time Series*
- *Admin* dapat menjalankan atau memproses prediksi hasil produksi berdasarkan *Data Time Series*.
- *Admin* dapat melihat prediksi hasil produksi.
- *Admin* dapat mengunduh laporan.

3. Petugas Lapangan

- Petugas lapangan bisa melakukan login dengan akun yang sudah didaftarkan oleh *admin*.
- Petugas lapangan dapat menginput data *real-time* seperti data lingkungan, perawatan, dan hasil produksi ke dalam aplikasi secara langsung.


3.2.3 Analisis Kebutuhan Non-Fungsional

Analisis kebutuhan non-fungsional dilakukan untuk mengetahui spesifikasi kebutuhan yang mendukung perancangan, pengembangan, dan implementasi aplikasi secara keseluruhan. Kebutuhan non-fungsional ini berperan penting dalam memastikan sistem berjalan dengan efisien, aman, stabil, serta mudah digunakan oleh pengguna akhir, sehingga dapat memenuhi standar kualitas yang diharapkan. Analisis kebutuhan non-fungsional terbagi menjadi dua bagian utama, yaitu analisis perangkat keras yang mencakup spesifikasi seperti kapasitas prosesor, memori, dan penyimpanan, serta analisis perangkat lunak yang melibatkan kompatibilitas dengan sistem operasi, *database*, dan *tools* pendukung lainnya.

1. *System Operasi MacOS.*
2. *Laptop Macbook Air M1.*
3. *Aplikasi Code Editor Visual Studio Code atau Google Colab.*
4. *Aplikasi PostgreSQL.*
5. *Aplikasi Browser Google Chrome.*

3.2.4 Use Case Diagram

Use Case Diagram adalah representasi visual menggunakan notasi *Unified Modeling Language* (UML) yang menggambarkan interaksi antara pengguna (aktor) dengan sebuah sistem untuk mencapai tujuan tertentu. Pada tahapan ini terdapat 3 aktor yaitu Asisten Kepala, kerani (*Admin*) dan petugas lapangan yang. Penjelasan pada tahap ini diilustrasikan pada Gambar 3.1.



Gambar 3. 1 *Use Case Diagram*

Menggambarkan *Use Case Diagram* yang memiliki tiga aktor yaitu Asisten Kepala, Kerani (*Admin*) dan Petugas Lapangan, serta enam *Use Case* yaitu Login, Kelola Data Time Series, Input Data Time Series, Input Data Real-time, Memproses Prediksi Hasil Produksi, Lihat Hasil Produksi, dan Mengunduh Laporan.

1. Definisi Aktor

Definisi aktor pada sistem dideskripsikan pada Tabel 3.2. Aktor-aktor ini merepresentasikan peran pengguna yang terlibat langsung dalam pengoperasian sistem dan memiliki tanggung jawab serta akses yang berbeda-beda sesuai dengan fungsinya.

Tabel 3. 2 Definisi Aktor

No	Aktor	Deskripsi
1	Asisten Kepala	Pengambil keputusan utama yang memantau hasil prediksi, memberikan instruksi pemeliharaan tambahan dan laporan hasil produksi.

2	Kerani (<i>Admin</i>)	Bertanggung jawab dalam mengelola data pengguna, mengelola Data <i>Time Series</i> , dan melihat laporan hasil produksi.
3	Petugas Lapangan	Bertugas untuk memasukkan data <i>real-time</i> terkait faktor lingkungan seperti curah hujan dan faktor perawatan seperti pemupukan.

Peran tiga aktor utama dalam sistem, yaitu Asisten Kepala, Kerani (*Admin*), dan petugas lapangan. Asisten Kepala bertindak sebagai pengambil keputusan utama dengan tugas memantau hasil prediksi, memberikan instruksi tambahan terkait pemeliharaan, dan menyusun laporan hasil produksi. Kerani bertanggung jawab dalam pengelolaan data pengguna, penyimpanan Data *Time Series*, serta akses terhadap laporan hasil produksi. Sementara itu, petugas lapangan berperan dalam pengumpulan data *real-time* terkait faktor lingkungan seperti curah hujan dan faktor perawatan pemupukan.

2. Definisi *Use Case*

Pada Tabel 3.3 akan mendefinisikan setiap case Login, Kelola Data *Time Series* dan pengguna, input data *real-time*, Memproses prediksi hasil produksi, Lihat hasil produksi, dan mengunduh laporan. Setiap *use case* menggambarkan alur aktivitas penting yang dilakukan oleh aktor dalam sistem untuk mencapai suatu tujuan tertentu.

Tabel 3. 3 Definisi *Use Case*

No	<i>Use Case</i>	Deskripsi
1	Login	Proses yang memungkinkan <i>user</i> Asisten Kepala, <i>Admin</i> , dan Petugas Lapangan akan diverifikasi sebelum memasuki sistem.
2	Kelola Data <i>Time Series</i> dan pengguna.	<i>Admin</i> dapat menambahkan, mengubah, atau menghapus Data <i>Time Series</i> dan <i>user</i> .

3	Input Data <i>Real-time</i>	Petugas melakukan penginputan data <i>real-time</i> dari faktor lingkungan, faktor perawatan, dan hasil produksi.
4	Memproses Prediksi Hasil Produksi	<i>Admin</i> menjalankan model prediksi berdasarkan data yang tersedia.
5	Lihat Hasil Prediksi	Petinggi dan admin dapat mengakses hasil prediksi yang dihasilkan oleh sistem berdasarkan data yang sudah dimasukkan.
6	Mengunduh Laporan	Asisten Kepala dapat mengunduh data atau laporan sesuai dengan kebutuhan.


Enam *use case* utama dalam sistem. *Use case* "Login" memungkinkan user seperti Asisten Kepala, *Admin*, dan Petugas Lapangan untuk diverifikasi sebelum mengakses sistem. Selanjutnya, *Admin* memiliki kemampuan untuk mengelola Data *Time Series* dan pengguna, termasuk menambahkan, mengubah, atau menghapus data. Petugas Lapangan bertugas menginput data *real-time* dari faktor lingkungan, faktor perawatan, dan hasil produksi. *Admin* dapat memproses prediksi hasil produksi menggunakan model berbasis data yang tersedia. Hasil prediksi ini dapat diakses oleh Asisten Kepala dan *Admin* untuk keperluan analisis. Terakhir, Asisten Kepala memiliki fitur untuk mengunduh laporan sesuai kebutuhan.

3.2.5 Activity Diagram

Activity Diagram adalah salah satu jenis diagram dalam Unified Modeling Language (UML) yang digunakan untuk menggambarkan alur kerja atau proses dinamis dalam sebuah sistem. Diagram ini memvisualisasikan urutan aktivitas, keputusan, dan aliran kontrol yang terjadi, mirip dengan flowchart tetapi lebih fleksibel untuk menangani aspek seperti paralelisme dan concurrency.

1. Activity Diagram Login

Tahapan *Activity Diagram* Login yang dapat diakses oleh *user* atau semua aktor dapat dilihat pada Gambar 3.2.




Gambar 3. 2 *Activity Diagram Login*

Proses ini dimulai dari sisi pengguna (user) yang memasukkan informasi kredensial mereka, yaitu username (atau email) dan password, melalui antarmuka seperti form login pada aplikasi web, mobile app, atau desktop. Pengguna biasanya mengisi data ini di halaman login yang dirancang dengan elemen UI sederhana, seperti input field untuk username dan password (yang sering ditampilkan sebagai teks tersembunyi untuk keamanan), serta tombol "Submit" atau "Login". Pada tahap keputusan, jika data tidak valid (*flase*), proses login dihentikan, dan *user* akan di beri pesan kesalahan. Sebaliknya, jika data valid (*True*), *user* akan diarahkan ke halaman *dashboard*, yaitu halaman utama setelah berhasil login.

2. *Activity* Proses Prediksi Hasil Produksi

Tahapan *Activity Diagram* Proses Prediksi Hasil Prediksi yang hanya bisa diakses oleh *admin* dapat dilihat pada Gambar 3.3.




Gambar 3. 3 *Activity* Proses Prediksi Hasil Produksi

Proses dimulai dari *Admin* menginput bulan dan tahun, kemudian menjalankan prediksi. Selanjutnya sistem melakukan pengecekan, apakah ada Dataset Sistem atau tidak, jika ada maka lanjut ke pemrosesan prediksi, jika tidak ada Dataset Sistem maka *Admin* harus melakukan penginputan Dataset Sistem dan melakukan penginputan ulang Bulan dan Tahun, kemudian menjalankan kembali prediksi. Selanjutnya sistem melakukan proses prediksi, kemudian

menyimpan hasil prediksi ke database dan menampilkan hasil prediksi. Selanjutnya *Admin* dapat melihat hasil prediksi.

3. *Activity Kelola Data Time Series*

Tahapan *Activity Diagram* Kelola Data Time Series yang hanya bisa diakses oleh *admin* yang dimana *admin* dapat mengelola dapat mengelola seluruh data pada sistem. *Activity Diagram* Kelola Data Time Series dapat dilihat pada Gambar 3.4.




Gambar 3. 4 *Activity Kelola Data Time Series*

Proses dimulai dengan *Admin* memilih menu Data Sistem, kemudian sistem menampilkan Data Dataset Sistem. Selanjutnya *Admin* bisa melakukan pengelolaan data pada Dataset Sistem, yang dimana admin bisa melakukan import, buat, edit, dan hapus data pada Dataset Sistem. Setelah *Admin* melakukan pengelolaan data Dataset Sistem, maka sistem melakukan validasi, dan setelah itu data yang telah dilakukan pengelolaan disimpan ke *Database*.

4. Activity Input Data Real-time

Tahapan *Activity Diagram* Input Data Real-time yang hanya bisa diakses oleh petugas lapangan dapat dilihat pada Gambar 3.5.




Gambar 3. 5 Activity Input Data Real-time

Petugas lapangan menginput data secara real-time, yang kemudian berlanjut ke sistem yang akan menerima inputan. Kemudian admin bisa melihat *Activity Log* petugas lapangan, dan sistem akan melakukan validasi otomatis. Apabila data valid, sistem akan menyimpannya ke dalam *Data Time Series*, dan petugas lapangan akan menerima Notifikasi Berhasil sebagai tanda bahwa proses telah selesai. Jika data tidak valid pada tahap konfirmasi oleh admin atau validasi oleh sistem, proses akan dihentikan. Diagram ini memastikan pengelolaan data yang terstruktur, valid, dan tersimpan dengan baik untuk kebutuhan *time series*.

5. *Activity* Lihat Hasil Prediksi

Tahapan *Activity Diagram* Lihat Hasil Prediksi yang hanya bisa dilihat oleh Askep dan admin dapat dilihat pada Gambar 3.6.




Gambar 3. 6 *Activity Diagram* Lihat Hasil Prediksi

Proses dimulai dari Askep dan *Admin* yang mengakses Menu Hasil Prediksi. Sistem kemudian menampilkan daftar prediksi yang tersedia. Askep dan *Admin* memilih prediksi tertentu, dan Sistem menampilkan hasil prediksi tersebut dalam berbagai format, seperti tabel, grafik, atau angka. Diagram ini menunjukkan interaksi antara pengguna dan sistem secara berurutan, dengan fokus pada penyajian data prediksi yang mudah diinterpretasikan oleh pengguna.

6. *Activity* Mengunduh Laporan

Tahapan *Activity Diagram* Mengunduh Laporan yang bisa diakses oleh semua aktor dapat dilihat pada Gambar 3.7.




Gambar 3. 7 *Acitivity Diagram* Mengunduh Laporan

Proses dimulai ketika actor membuka “Menu Laporan” dan memilih laporan bersarkan waktu tertentu. Setelah itu, aktor manager mengklik tombol “Unduh”, yang akan memicu sistem untuk memproses permintaan dengan menampilkan laporan, kemudian aktor memimilik laporan dengan waktu tertentu untuk di unduh, kemudian sistem memproses unduhan dan mempersiapkan file file laporan untuk diunduh. Setelah proses selesai, file laporan diterima oleh aktor manger.

3.2.6 *Class Diagram*

Diagram kelas (*class diagram*) merupakan salah satu diagram struktur dalam UML (*Unified Modeling Language*) yang digunakan untuk menggambarkan secara rinci struktur kelas, atribut, metode, serta relasi antar objek. Diagram ini bersifat statis, artinya tidak menggambarkan alur interaksi

ketika kelas-kelas saling berhubungan, melainkan menunjukkan jenis hubungan yang ada di antara mereka. Diagram kelas untuk sistem prediksi hasil produksi kelapa sawit ditampilkan pada Gambar 3.8.




Gambar 3. 8 *Class Diagram*

Terdapat beberapa entitas kunci, yaitu Afdeling, Blok, Tahun Tanam, Pemupukan, Produksi, Dataset, Curah Hujan, dan Prediksi. Setiap entitas memiliki atribut spesifik yang mencakup *id*, nama, dan data numerik seperti dosis dan volume untuk Pemupukan, serta rencana dan realisasi produksi untuk Produksi. Hubungan antar entitas menunjukkan bagaimana informasi saling terkait, misalnya, Blok terhubung dengan Afdeling, sedangkan Pemupukan dan Produksi terkait dengan Tahun Tanam. Diagram ini menciptakan gambaran komprehensif mengenai proses dan pengelolaan data dalam kegiatan pertanian,

memungkinkan pengguna untuk memahami alur pengumpulan dan penggunaan data untuk prediksi hasil produksi.

3.2.7 Flowchart Sistem

Flowchart atau diagram alir atau bagan alir merupakan gambaran dalam bentuk diagram alir dari algoritma-algoritma dalam suatu program yang menyatakan arah alur program tersebut. *Flowchart Sistem* prediksi hasil produksi kelapa sawit dapat dilihat pada Gambar 3.9.




Gambar 3. 9 *Flowchart Sistem*

Flowchart sistem prediksi hasil produksi kelapa sawit yang dimulai dari petugas lapangan input data harian berupa pemupukan dan hasil produksi. Data yang masuk akan disimpan dan dilanjutkan ke proses penjumlahan data harian menjadi bulanan, kemudian lanjut ke proses verifikasi apakah data sudah mencakup minimal 12 bulan. Jika belum, *Admin* diminta melengkapi data secara manual atau melakukan import dataset yang tersedia. Jika data sudah lengkap, *Admin* akan melakukan proses prediksi pada sistem. Hasil dari prediksi ini disimpan ke dalam arsip prediksi. Kemudian Arsip Prediksi dibentuk menjadi sebuah Laporan yang nantinya dilihat oleh *Manager* untuk melakukan keputusan lanjutan.

3.2.8 Arsitektur Umum Sistem Prediksi Hasil Produksi

Ilustrasi dari arsitektur umum perancangan sistem prediksi hasil produksi dapat dilihat pada Gambar 3.10.



Gambar 3. 10 Arsitektur Umum Sistem Prediksi Hasil Produksi

mengilustrasikan arsitektur umum sistem prediksi produksi kelapa sawit, di mana petugas lapangan bertanggungjawab menginput data *real-time* terkait faktor lingkungan seperti suhu, curah hujan, kelembaban, serta perawatan tanaman termasuk pemupukan, pengendalian hama, dan pemangkasan melalui aplikasi *mobile* yang *user-friendly* untuk pengiriman instan dan akurat guna mendeteksi masalah dini. Sementara itu, operator atau admin mengelola data *time series* seperti tren produksi bulanan dan pola pertumbuhan historis melalui aplikasi berbasis *website*, membersihkan data, menyimpannya ke *database*, serta menjalankan prediksi untuk estimasi *yield* seperti jumlah tandan buah segar yang dipanen. Hasil prediksi ini kemudian dimanfaatkan oleh asisten kepala sebagai dasar pengambilan keputusan strategis, termasuk perencanaan panen optimal, alokasi sumber daya, dan strategi pemasaran, dengan opsi mengunduh laporan dalam format PDF atau *spreadsheet* yang mencakup grafik dan analisis mendalam. Pada sisi *backend*, model *Long Short-Term Memory* (LSTM) dari machine learning digunakan untuk memproses dan menganalisis data *time series* dengan kemampuan mengingat pola jangka panjang, berinteraksi melalui API untuk komunikasi efisien antara *frontend* (aplikasi *mobile* dan *web*) dengan *database*, memastikan keamanan data via enkripsi dan autentikasi.

3.2.9 Perancangan Antarmuka (User Interface)

Perancangan *User Interface* pada sistem ini bertujuan untuk menciptakan tampilan yang dapat memandu pengguna dalam mengoperasikan program sistem kedepannya. Berikut adalah rancangan antarmuka yang akan dibangun.

a. User Petugas Lapangan

1. User Interface Login

User Interface login Petugas Lapangan dapat dilihat secara lebih jelas pada Gambar 3.11 yang menampilkan elemen-elemen penting seperti kolom *input* untuk *username* dan *password*, serta tombol untuk masuk ke dalam sistem.


The wireframe shows a vertical rectangular container. At the top center is the word "Logo" in a large, bold, sans-serif font. Below it, centered, is the text "Prediction Oil Palm" in a bold font, followed by "Masuk ke akun Anda" in a smaller, regular font. There are two input fields: the first is labeled "Email" and the second is labeled "Password", both in a regular font. Below these fields is a "Login" button. All text is centered within the container.

Gambar 3. 11 *Interface Login Petugas Lapangan*

Wireframe yang ditampilkan menggambarkan arsitektur aplikasi yang dirancang untuk mengintegrasikan berbagai pengguna, termasuk *Admin*, Petugas Lapangan, dan *Manager*, dalam sebuah ekosistem berbasis *website* yang berfokus pada prediksi dan pengelolaan data secara efisien. Aplikasi ini memungkinkan Petugas Lapangan untuk menginput data *real-time* melalui antarmuka aplikasi *mobile* yang intuitif, mencakup informasi seperti kondisi lingkungan, status tanaman, atau aktivitas perawatan, yang kemudian dikirimkan secara otomatis ke *backend* untuk diproses lebih lanjut.

2. *User Interface Beranda*

User Interface beranda yang diakses oleh *petugas lapangan* dapat dilihat secara lebih jelas pada Gambar 3.12.




Gambar 3. 12 *Interface* Beranda Petugas Lapangan

Wireframe yang menggambarkan arsitektur sistem yang melibatkan interaksi antara pengguna, *website*, *backend*, dan *mobile*. Tiga jenis pengguna *Admin*, petugas lapangan, dan manager mengakses website untuk melakukan prediksi dan pengelolaan data. Data yang diinput melalui aplikasi mobile akan dilaporkan dan selanjutnya diproses oleh backend menggunakan model *Long Short-Term Memory* (LSTM) untuk menghasilkan prediksi.

b. *User Admin*

1. *User Interface Login*

User Interface login *Admin* dapat dilihat secara lebih jelas pada Gambar 3.13 yang menampilkan elemen-elemen penting seperti kolom input untuk *username* dan *password*, serta tombol untuk masuk ke dalam sistem.



Prediction Oil Palm
Masku ke akun Anda

Email


Password

Gambar 3. 13 *Interface Login*

Wireframe yang menggambarkan halaman login untuk *admin* dalam sistem prediksi hasil produksi kelapa sawit dirancang dengan konsep yang sederhana namun efektif, mengutamakan kemudahan penggunaan sekaligus responsif terhadap perangkat mobile.

2. *User Interface Dashboard*

User Interface Dashboard berfungsi untuk menampilkan ringkasan data, monitoring aktivitas, navigasi cepat, dan visualisasi data. Untuk perancangan *User Interface Dashboard* dapat dilihat pada Gambar 3.14.



Logo Name 

Dashboard

Total Blok 0 Total Produksi 0 Total Luas Lahan 0

Grafik Perbandingan antara Data Aktual dan Hasil Prediksi


Top Blok Produktif Aktivitas Terkini

Gambar 3. 14 *Interface Dashboard*

Wireframe dashboard aplikasi prediksi produksi kelapa sawit berbasis web. Antarmuka ini dirancang dengan *sidebar* navigasi di kiri, *header* atas berisi logo dan info pengguna, serta tampilan utama di tengah yang memuat ringkasan data, grafik perbandingan prediksi vs aktual, dan informasi blok produktif serta aktivitas terbaru.

3. *User Interface* Data Karyawan

User Interface Data Karyawan akan menyajikan data-data karyawan yang bertugas di PTPN IV Regional VI KSO. Untuk perancangan *User Interface* Data Karyawan dapat dilihat pada Gambar 3.15.




No	Nama Karyawan	Jabatan	Tanggal Masuk	Lokasi Kerja	Lama Kerja	Action
1	-	-	-	-	-	[Edit] [Delete]
2	-	-	-	-	-	[Edit] [Delete]
3	-	-	-	-	-	[Edit] [Delete]
4	-	-	-	-	-	[Edit] [Delete]
5	-	-	-	-	-	[Edit] [Delete]
7	-	-	-	-	-	[Edit] [Delete]
8	-	-	-	-	-	[Edit] [Delete]

Gambar 3. 15 *Interface* Data Karyawan

Wireframe menggambarkan rancangan halaman manajemen data karyawan dalam sistem prediksi hasil produksi kelapa sawit berbasis website. Tampilan ini menyajikan tabel data karyawan dengan kolom-kolom informasi seperti nomor, nama karyawan, jabatan, tanggal masuk, lokasi kerja, dan lama kerja. Setiap baris data dilengkapi dengan ikon aksi di kolom “*Action*” yang memungkinkan pengguna untuk melakukan edit atau hapus data. Menu navigasi di sisi kiri tetap konsisten dengan halaman sebelumnya, memudahkan perpindahan antar modul dalam sistem. Desain ini mempermudah admin dalam mengelola informasi karyawan yang berperan dalam operasional maupun pengumpulan data lapangan untuk keperluan prediksi produksi.

4. *User Interface Afdeling*

User Interface Afdeling menyajikan menu bagian afdeling yang nantinya untuk menampilkan data-data terkait hasil produksi dan pemupukan. Untuk perancangan *User Interface Afdeling* dapat dilihat pada Gambar 3.16.




Gambar 3. 16 *Interface Afdeling*

Wireframe yang menggambarkan rancangan halaman monitoring afdeling dalam sistem prediksi hasil produksi kelapa sawit berbasis *website*. Halaman ini menampilkan daftar beberapa afdeling (unit atau bagian wilayah kebun) dalam bentuk kartu, seperti Afdeling 1 hingga Afdeling 5, yang masing-masing dapat diklik untuk melihat detail atau data lebih lanjut terkait wilayah tersebut. Penempatan elemen yang rapi dan visual yang sederhana memudahkan pengguna, seperti petugas atau admin, untuk memilih dan memantau data per afdeling secara cepat, seperti curah hujan, pemupukan, atau hasil produksi. Navigasi sisi kiri tetap konsisten, menjaga pengalaman pengguna yang terstruktur dalam sistem.

5. *User Interface Dataset Sistem*


User Interface Dataset Sistem menyajikan data-data total curah hujan, pemupukan, dan hasil produksi. Untuk perancangan *User Interface Data Sistem* dapat dilihat pada Gambar 3.17.

Gambar 3. 17 *Interface* Dataset Sistem

Wireframe halaman manajemen Dataset Sistem pada aplikasi prediksi produksi kelapa sawit. Halaman ini berisi tabel data *time series* dengan kolom tanggal, curah hujan, pemupukan, dan hasil produksi. Disediakan tombol aksi untuk edit dan hapus, serta fitur Tambah, Import, dan Ekspor di kanan atas untuk pengelolaan data secara manual maupun massal.

6. *User Interface* Curah Hujan


User Interface Curah Hujan merupakan halaman untuk memproses normalisasi data yang akan digunakan untuk diprediksi. Untuk perancangan *User Interface* Curah Hujan dapat dilihat pada Gambar 3.18.

Gambar 3. 18 *Interface* Curah Hujan

Wireframe halaman data curah hujan yang menampilkan tabel berisi nomor, tanggal, dan nilai curah hujan, serta tombol edit dan hapus. Data ini merupakan variabel penting dalam prediksi produksi kelapa sawit. Desainnya yang sederhana memudahkan pengguna dalam memantau dan mengelola data iklim secara efisien.

7. *User Interface* Prediksi

User Interface Prediksi merupakan halaman untuk memproses data prediksi sesuai blok panen yang dipilih. Untuk perancangan *User Interface* Prediksi dapat dilihat pada Gambar 3.19.




Gambar 3. 19 *Interface* Prediksi

Wireframe yang menggambarkan rancangan halaman Prediksi dalam sistem prediksi hasil produksi kelapa sawit berbasis *website*. Pada halaman ini, pengguna dapat memilih bulan dan tahun tertentu untuk melakukan prediksi produksi kelapa sawit menggunakan model yang telah dibangun sebelumnya. Setelah memilih periode dan menekan tombol Prediksi, hasil prediksi akan ditampilkan di bagian bawah dalam area “Hasil Prediksi”.

8. *User Interface* Arsip Prediksi

User Interface Arsip Prediksi merupakan halaman untuk menampilkan hasil prediksi yang sudah di proses. Untuk perancangan *User Interface* Arsip Prediksi dapat dilihat pada Gambar 3.20.




Gambar 3. 20 *Interface* Arsip Prediksi

Wireframe yang menggambarkan rancangan halaman Arsip Prediksi dalam sistem prediksi hasil produksi kelapa sawit berbasis *website*. Halaman ini menampilkan tabel arsip berisi data hasil prediksi yang telah dilakukan sebelumnya, dengan kolom seperti nomor, bulan, tahun, hasil prediksi, dan kolom aksi untuk mengedit atau menghapus data. Di bagian bawah juga disediakan area untuk menampilkan detail dari hasil prediksi yang dipilih. Fitur ini berguna bagi pengguna untuk menyimpan riwayat prediksi, melakukan penelusuran hasil sebelumnya, dan melakukan evaluasi terhadap akurasi model dari waktu ke waktu. Desainnya yang bersih dan terstruktur memudahkan pengelolaan serta pelacakan data prediksi secara efisien.

c. *User Manager*

1. Laporan

User Interface Laporan merupakan halaman untuk menampilkan laporan yang nantinya bisa digunakan sebagai acuan manager untuk mengambil keputusan lanjutan. Untuk perancangan *User Interface* Laporan dapat dilihat pada Gambar 3.21.



Gambar 3. 21 *User Interface* Laporan

Menunjukkan desain antarmuka untuk sebuah laporan komprehensif yang mencakup informasi seperti total blok, pokok, dan pemupukan, disertai dengan visualisasi berupa grafik untuk tren produksi dan distribusi pemupukan. Desain ini mengadopsi tata letak sederhana dan terstruktur dengan bagian-bagian yang jelas, memungkinkan pengguna untuk dengan mudah memahami data yang disajikan melalui kombinasi teks dan grafik.

3.2 Data dan Pengumpulan Data

Data yang digunakan dalam penelitian ini merupakan data deret waktu (*time series*) yang mencakup faktor lingkungan (curah hujan), perawatan tanaman (pemupukan), dan hasil produksi kelapa sawit dari PTPN IV Regional 6 KSO unit Kebun Lama. Data pemupukan dan hasil produksi dikumpulkan dari catatan

perusahaan sebagai sumber primer dan *Google Earth Engine* sebagai sumber sekunder untuk variabel curah hujan [27]. Namun, untuk variabel pemupukan serta hasil produksi, sebagian data merupakan data *dummy* yang dibuat secara sintetis. Penggunaan data *dummy* ini diintegrasikan dengan data asli untuk memperkaya dataset, memastikan ukuran sampel yang memadai bagi pelatihan model *Long Short-term Memory* (LSTM).

Pengumpulan data *real* pemupukan dan hasil produksi yang didapatkan dari perusahaan dijumlahkan secara bulanan dengan jumlah 48 data untuk periode 1 Januari 2021 hingga 31 Desember 2024. Data curah hujan juga dikumpulkan secara bulanan dengan total 228 data untuk periode 1 Januari 2005 hingga 31 Desember 2024. Untuk mengatasi ketidakcocokan periode data (di mana data curah hujan mencakup periode lebih panjang), *matching* dilakukan melalui agregasi bulanan dan peyelarasan temporal, data curah hujan historis (2005–2020) digunakan sebagai basis untuk mensimulasikan pola *dummy* data pemupukan dan hasil produksi, dengan asumsi pola musiman yang serupa berdasarkan literatur pertanian kelapa sawit (seperti pengaruh curah hujan terhadap pertumbuhan tanaman). Selain itu, data *dummy* pemupukan dan hasil produksi digenerasikan sebanyak 180 data untuk menyelaraskan data curah hujan menggunakan *script python* dengan mempertimbangkan faktor lingkungan dan perawatan. Untuk melihat *script python* pembuatan dataset *dummy* bisa dilihat pada Lampiran 1.

Data yang sudah tersedia sebanyak 228 data kemudian dibentuk menjadi dataset yang dibagi dengan proporsi 80% untuk data *training* dan 20% untuk data *testing*. Proporsi ini dipilih berdasarkan praktik standar untuk data *time series* berukuran sedang, di mana data *training* yang lebih besar memungkinkan model LSTM belajar pola kompleks tanpa mengorbankan ukuran data *testing* untuk evaluasi. Selain itu, pendekatan ini membantu dalam mencegah overfitting pada data pelatihan sekaligus memastikan generalisasi model terhadap data baru. Hasil dari data *real* yang didapatkan dan data *dummy* yang di *generate* menggunakan *script python* dapat dilihat pada Tabel 3.4.

Tabel 3. 4 Data *Real* dan *Dummy*

Curah Hujan	Pemupukan	Hasil Produksi
2005	2005	2005
2006	2006	2006
2007	2007	2007
2008	2008	2008
2009	2009	2009
2010	2010	2010
2011	2011	2011
2012	2012	2012
2013	2013	2013
2014	2014	2014
2015	2015	2015
2016	2016	2016
2017	2017	2017
2018	2018	2018
2019	2019	2019
2020	2020	2020
2021	2021	2021
2022	2022	2022
2023	2023	2023
2024	2024	2024

Ket:

 Data *Real*
 Data *Dummy*


Teknik yang digunakan untuk menghasilkan data *dummy* adalah model matematis dan simulasi berbasis pola. Data *dummy* di *generate* berdasarkan pola musiman yang umum terjadi dalam data meteorologi dan pertanian. Teknik ini menggunakan fungsi matematika seperti sinus ($\sin(x)$) dan cosinus ($\cos(x)$) untuk meniru fluktuasi yang terjadi secara berkala setiap tahun. Curah hujan dibuat dengan pola sinusoidal ($200 + 100 \cdot \sin(\dots)$) yang mencerminkan musim hujan dan kemarau. Pemupukan dibuat dengan pola cosinus ($300 + 50 \cdot \cos(\dots)$) yang dapat meniru jadwal pemupukan berkala dalam satu tahun. Kemudian, penambahan

random noise yang bertujuan agar data terlihat lebih realistis dengan menggunakan fungsi *np.random.normal()* untuk menambahkan variasi acak yang kecil pada data musiman.

Berikut sampel data berdasarkan faktor lingkungan dan perawatan serta sampel hasil produksi:

a. Faktor Lingkungan

Data yang digunakan pada faktor lingkungan yaitu data curah hujan. Data diambil melalui *website Google Earth Engine* dengan melakukan konfigurasi *coding* untuk mengambil data curah hujan yang berada daerah Aceh Tamiang. *Flowchart* pengambilan data curah hujan menggunakan *Google Earth Engine CHIRPS Daily* dapat dilihat pada Gambar 3.22.



Gambar 3. 22 *Flowchart* pengambilan data curah hujan

Menggambarakan alur proses pengambilan data curah hujan melalui *website Google Earth Catalog Engine CHIRPS Daily* dengan menggunakan *script python* yang menghasilkan data curah hujan harian. Kemudian data curah hujan

di kelola lagi menggunakan *script python* untuk mengubah atau menjumlahkan data curah hujan harian menjadi bulanan.

b. Faktor Perawatan

Pemupukan tanaman adalah aspek manajemen agronomis. Data ini bersumber dari catatan perusahaan PTPN IV REGIONAL 6 KSO, termasuk dosis dan volume pemupukan dalam format deret waktu, pada penelitian ini menggunakan volume pemupukan sebagai inputan ke dalam model LSTM. Pemupukan penting untuk menyediakan nutrisi esensial (seperti N, P, K), yang secara langsung meningkatkan kesehatan tanaman dan hasil produksi.

c. Hasil Produksi


Hasil produksi merujuk pada data output panen kelapa sawit dalam satuan kg, yang juga bersumber dari catatan PTPN IV Regional 6 KSO. Data ini dikumpulkan melalui laporan produksi bulanan yang diakumulasi. Pengumpulan difokuskan pada data time series untuk mendukung prediksi. Variabel ini menjadi target output model LSTM, yang dievaluasi untuk akurasi prediksi berdasarkan faktor lingkungan dan perawatan.

3.3 Rancangan Model

Rancangan model dalam penelitian ini menguraikan tahapan-tahapan pembuatan model *Long Short-Term Memory* (LSTM), mulai dari persiapan data hingga perancangan model LSTM.

3.2.1 Desain Pengelolaan Data

Desain pengelolaan data ini menggambarkan tahapan-tahapan yang digunakan dalam penelitian untuk mempersiapkan dan memproses data yang relevan sebelum analisis lebih lanjut. Tujuannya adalah untuk memastikan kualitas dan konsistensi data, yang sangat krusial untuk menghasilkan model optimal. Desain pengelolaan data dapat dilihat pada Gambar 3.23.




Gambar 3. 23 Desain Pengelolaan Data

Proses pengelolaan data dimulai dengan tahapan pengumpulan dan integrasi data. Data internal dari PTPN IV Regional 6 KSO unit Kebun Lama, yang terdiri dari data pemupukan dan data hasil produksi, dikumpulkan dan diintegrasikan dengan data curah hujan eksternal yang diperoleh dari *Google Earth Engine CHIRPS Daily*. Setelah itu, data dimuat ke dalam sebuah format dataset untuk diproses lebih lanjut. Setelah data terintegrasi, dilakukan tahapan pra-pemrosesan data (*preprocessing*) untuk memastikan kualitas dan konsistensi data sebelum analisis. Tahap pertama adalah interpolasi data, yang bertujuan mengatasi nilai yang hilang (*missing values*). Proses ini melibatkan identifikasi data yang hilang,

seperti nilai "*NaN*" (*Not a Number*), dilanjutkan dengan pemilihan teknik interpolasi yang paling sesuai dengan karakteristik dataset. Tahap selanjutnya adalah penanganan *outlier*, yang berfungsi untuk membersihkan data dari nilai-nilai ekstrem atau anomali. Langkah-langkah dalam penanganan outlier meliputi analisis penyebab *outlier* untuk memahami apakah nilai tersebut merupakan kesalahan atau data *valid*, diikuti dengan penerapan salah satu metode penanganan, seperti penghapusan (*removal*) baris atau kolom, transformasi (*transformation*) menggunakan metode seperti *log* atau akar kuadrat untuk mengurangi pengaruhnya, atau imputasi (*imputation*) dengan mengganti outlier menggunakan nilai rata-rata, median, atau perkiraan model. Tahap terakhir adalah normalisasi data, yang bertujuan menyeragamkan skala nilai pada seluruh fitur untuk menghindari bias pada model analisis, terutama pada algoritma machine learning yang sensitif terhadap skala seperti neural networks atau k-means clustering. Dalam penelitian ini, teknik *Min-Max Normalization* dipilih karena sederhana dan efektif untuk data dengan rentang nilai yang diketahui, di mana nilai diubah menjadi skala antara 0 dan 1. Proses ini mencakup penentuan teknik normalisasi yang sesuai, perhitungan parameter (nilai minimum dan maksimum) dari setiap fitur, dan transformasi data dengan menerapkan rumus normalisasi pada setiap titik data. Setelah melalui semua tahapan ini, dataset dianggap siap untuk di proses pada model. Proses pengelolaan data secara keseluruhan ini tidak hanya meningkatkan akurasi hasil, tetapi juga memungkinkan replikasi penelitian di masa depan dengan data yang lebih berkualitas.

3.2.2 Desain Model Prediksi

Desain model prediksi yang digunakan dalam penelitian ini yaitu menggunakan metode *Long Short-term Memory* dengan memprediksi hasil produksi berdasarkan faktor lingkungan dan perawatan, serta data hasil produksi. Proses tahapan desain model prediksi menggunakan metode *Long Short-term Memory* dapat dilihat pada Gambar 3.24.



Gambar 3. 24 Desain Model Prediksi

Pada langkah awal, data dibagi menjadi dua set, 80% untuk pelatihan dan 20% untuk pengujian, sebuah langkah untuk mencegah kebocoran data dan memastikan bahwa evaluasi kinerja model benar-benar objektif pada data yang sama sekali baru. Setelah pemisahan, data diolah menjadi urutan (*sequence*) yang terstruktur, dengan setiap sampel input terdiri dari 12 *time steps* yang mencakup dua fitur, curah hujan dan pemupukan, sebuah desain yang disengaja untuk menangkap dan mempelajari pola musiman tahunan. Arsitektur model yang digunakan adalah *Long Short-Term Memory* (LSTM) dua *layer* (lapis), di mana

layer pertama (128 *neuron*) berperan sebagai fondasi untuk menyerap dan mengidentifikasi dinamika data yang kompleks, sedangkan lapisan kedua (64 *neuron*) bertugas untuk menyaring informasi esensial dan mereduksi dimensi, menciptakan representasi yang lebih ringkas dan efisien. Di antara setiap lapisan, diterapkan *dropout* 0.3 yang secara acak menonaktifkan neuron untuk mencegah ketergantungan berlebihan dan meningkatkan kemampuan generalisasi model, sehingga model tidak hanya menghafal data pelatihan, dan sedikit berpengaruh untuk mengurangi terjadinya *overfitting*. Untuk mengoptimalkan pembelajaran, model ini dikompilasi menggunakan *optimizer Adam*, yang secara adaptif menyesuaikan kecepatan pembelajaran, dan dilatih selama 100 *epoch* dengan ukuran *batch* 16, memastikan proses pembelajaran yang stabil dan efektif tanpa risiko *overfitting* yang berlebihan. Terakhir, setelah prediksi dibuat, hasilnya dinormalisasi kembali ke skala aslinya dan dievaluasi secara ketat menggunakan tiga metrik utama yaitu MAE untuk kesalahan rata-rata, RMSE untuk sensitivitas terhadap kesalahan besar, dan R^2 Score untuk mengukur seberapa baik variabilitas data dijelaskan oleh model.

3.4 Teknik Pengujian

Hasil Penelitian ini akan diuji menggunakan pengujian *Black Box* dan pengujian penerja model prediksi menggunakan metrik MAE, RMSE, dan R^2 Score. Tujuan dari pengujian ini adalah untuk menguji fungsionalitas data dan melihat seberapa optimalnya model dalam melakukan prediksi.

3.4.1 Pengujian *Black Box*

Pengujian ini berfokus pada pengujian fungsionalitas sistem berdasarkan spesifikasi tanpa melihat implementasi internal atau kode program. Pengujian ini dilakukan untuk memastikan bahwa semua fungsi sistem berjalan sesuai dengan kebutuhan. Penguji memberikan input pada sistem dan memeriksa apakah output yang dihasilkan sesuai dengan yang diharapkan. Pengujian *Black Box* juga mencakup pengujian validasi input, navigasi antarhalaman, serta respon terhadap aksi pengguna.

1. Skenario pengujian halaman login *admin*

Skenario pengujian login yang terdiri dari 4 pengujian dapat dilihat pada Tabel 3.5.

Tabel 3. 5 Skenario pengujian halaman login admin

No	Pengujian	<i>Test Step</i>	Hasil yang Diharapkan
1	User <i>Admin</i> login dengan username benar dan passowrd benar	1. Input Username 2. Input Password 3. Klik tombol log in	User <i>Admin</i> berhasil masuk ke halaman dashboard
2	User <i>Admin</i> login dengan username benar dan password salah	1. Input Username 2. Input Password 3. Klik tombol log in	Menampilkan notif “username/pass word salah” dan tetap berada di halaman login
3	User <i>Admin</i> login dengan username salah dan password benar	1. Input Username 2. Input Password 3. Klik tombol log in	Menampilkan notif “username/pass word salah” dan tetap berada di halaman login
4	User <i>Admin</i> login dengan username salah dan password salah	1. Input Username 2. Input Password 3. Klik tombol log in	Menampilkan notif “username/pass word salah” dan tetap berada di halaman login

2. Skenario pengujian halaman login petugas lapangan

Skenario pengujian halaman login petugas lapangan yang terdiri dari 4 pengujian dapat dilihat pada Tabel 3.6.

Tabel 3. 6 Skenario pengujian halaman login petugas lapangan

No	Pengujian	Test Step	Hasil yang Diharapkan
1	User Petugas Lapangan login dengan username benar dan password benar	1. Input Username 2. Input Password 3. Klik tombol log in	User Petugas Lapangan berhasil masuk ke halaman dashboard
2	User Admin login dengan username benar dan password salah	1. Input Username 2. Input Password 3. Klik tombol log in	Menampilkan notif “username/pass word salah” dan tetap berada di halaman login
3	User Admin login dengan username salah dan password benar	1. Input Username 2. Input Password 3. Klik tombol log in	Menampilkan notif “username/pass word salah” dan tetap berada di halaman login
4	User Petugas Lapangan login dengan username salah dan password salah	1. Input Username 2. Input Password 3. Klik tombol log in	Menampilkan notif “username/pass word salah” dan tetap berada di halaman login

3. Skenario pengujian halaman prediksi *admin*

Skenario pengujian halaman prediksi *admin* yang terdiri dari 3 pengujian dapat dilihat pada Tabel 3.7.

Tabel 3. 7 Skenario pengujian halaman prediksi admin

No	Pengujian	Test Step	Hasil yang Diharapkan
1	User <i>Admin</i> menginput bulan dan tahun yang ingin diprediksi	1. Input Bulan 2. Input Tahun 3. Klik tombol prediksi	Menampilkan Hasil prediksi pada Bulan dan tahun yang diinginkan, serta menampilkan data Historikal 6 bulan sebelumnya yang digunakan untuk prediksi

2	User <i>Admin</i> menginput bulan dan tahun sebelumnya	1. Input Bulan 2. Input Tahun 3. Klik tombol prediksi	Menampilkan Notifikasi "Error Bulan/tahun target harus lebih baru dari data <i>time series</i> ."
3	User <i>Admin</i> menginput Bulan depan dan Tahu Saat ini	1. Input Bulan Depan 2. Input Tahun Saat ini 3. Klik tombol prediksi	Menampilkan Hasil prediksi pada Bulan dan tahun yang diinginkan, serta menampilkan data Historikal 6 bulan sebelumnya yang digunakan untuk prediksi

4. Skenario pengujian input data halaman beranda petugas lapangan

Skenario pengujian input data pemupukan dan hasil produksi halaman beranda petugas lapangan yang terdiri dari 2 pengujian dapat dilihat pada Tabel 3.8.

Tabel 3. 8 Skenario pengujian input data halaman beranda petugas lapangan

No	Pengujian	<i>Test Step</i>	Hasil yang Diharapkan
1	Input Data Pemupukan	1. Input Tanggal 2. Input Blok 3. Input Dosis Pupuk 4. Input Volume Pupuk 5. Tombol Submit	Menampilkan Hasil prediksi pada Bulan dan tahun yang diinginkan, serta menampilkan data Historikal 6 bulan sebelumnya yang digunakan untuk prediksi
2	Input Data Hasil Produksi	1. Input Tanggal 2. Input Blok 3. Input Hasil Produksi 4. Tombol Submit	Menampilkan Notifikasi "Error Bulan/tahun target harus lebih baru dari data <i>time series</i> ."

5. Skenario pengujian *logout*

Skenario pengujian *logout* yang terdiri dari 1 pengujian dapat dilihat pada Tabel 3.9.

Tabel 3. 9 Skenario pengujian *logout*

No	Pengujian	Test Step	Hasil yang Diharapkan
1	User <i>Admin</i> melakukan <i>Logout</i> pada Aplikasi	1. Admin menekan avatar profil 2. Menekan tombol <i>logout</i>	Berhasil <i>Logout</i> dan redirect ke halaman Login

3.4.2 Pengujian Model Menggunakan Metrik *MAE*, *RMSE*, dan *R2 Score*

Pengujian ini bertujuan untuk mengevaluasi akurasi dan keandalan model prediksi yang digunakan dalam sistem, menggunakan data uji. Pengujian ini berfokus pada algoritma *LSTM* yang menjadi inti dari sistem prediksi. Data time-series yang tidak digunakan dalam pelatihan model digunakan sebagai dataset pengujian, yang artinya pengujian metrik ini menggunakan data *testing*. Evaluasi ini dilakukan menggunakan tiga metrik utama, yaitu:

1. *Mean Absolute Error* (MAE)

MAE berfungsi untuk mengukur rata-rata kesalahan absolut antara hasil prediksi dan nilai aktual. Nilai MAE yang lebih kecil menunjukkan bahwa prediksi model lebih mendekati nilai sebenarnya. Skenario dari metrik MAE dapat dilihat pada Tabel 3.10.

Tabel 3. 10 Skenario MAE

No	Langkah	Input yang digunakan	Output yang diharapkan
1	Menyiapkan data aktual	Dataset aktual hasil produksi pada periode pengujian	Data aktual yang siap digunakan
2	Menyiapkan hasil prediksi	Hasil prediksi model <i>LSTM</i> pada periode pengujian	Deret nilai prediksi untuk setiap timestamp pada test set
3	Menghitung error absolut	Nilai aktual dan nilai prediksi	Daftar selisih absolut $ y_i - \hat{y}_i $.

4	Mengakumulasikan total error	Hasil selisih absolut	Nilai total error $\sum y_i - \hat{y}_i $.
5	Menghitung Nilai MAE	Nilai total <i>error</i> dan jumlah data n	Nilai Mean Absolute Error (MAE) $\frac{1}{n} \sum_{t=1}^n Y_i - \hat{Y}_i $

Keterangan:

$\hat{y}_i$: Nilai prediksi

y_i : Nilai aktual / Nilai sebenarnya

n : Jumlah data

2. Root Mean Square Error (RMSE)

RMSE menghitung akar kuadrat dari rata-rata kuadrat kesalahan. Metrik ini memberikan penalti lebih besar terhadap kesalahan yang besar dibandingkan MAE, sehingga lebih sensitif terhadap outlier. RMSE yang rendah menunjukkan performa model yang lebih baik dalam menangkap pola data. Skenario dari metrik RMSE dapat dilihat pada Tabel 3.11.

Tabel 3. 11 Skenario RMSE

No	Langkah	Input yang digunakan	Output yang diharapkan
1	Menyiapkan data aktual (Data pengujian)	Dataset aktual hasil produksi pada periode pengujian	Data aktual yang siap digunakan
2	Menyiapkan hasil prediksi	Hasil prediksi model LSTM pada periode pengujian	Deret nilai prediksi untuk setiap timestamp pada test set
3	Menghitung error kuadrat	Nilai aktual dan nilai prediksi	Deret error kuadrat $(y_i - \hat{y}_i)^2$
4	Mengakumulasi total error kuadrat	Hasil error kuadrat seluruh titik data	Nilai total error kuadrat $\sum (y_i - \hat{y}_i)^2$.

5	Menghitung nilai RMSE	Nilai total error dan jumlah data n	Nilai Root Mean Square Error (RMSE) $\sqrt{\frac{1}{n} \sum \frac{(y_i - \hat{y}_i)^2}{n}}$
---	-----------------------	---------------------------------------	--

Keterangan:

$\hat{y}_i$: Nilai prediksi

y_i : Nilai aktual / Nilai sebenarnya

n : Jumlah data

3. R^2 Score (*R-Squared*)

R^2 Score mengukur seberapa baik variansi dalam data aktual dapat dijelaskan oleh hasil prediksi model. Nilai R^2 Score berkisar antara 0 hingga 1, di mana nilai mendekati 1 menandakan bahwa model memiliki kemampuan prediksi yang sangat baik, sedangkan nilai negatif menunjukkan bahwa model lebih buruk dibandingkan rata-rata. Skenario dari matrik R^2 Score dapat dilihat pada Tabel 3.12.

Tabel 3. 12 Skenario R^2 Score

No	Langkah	Input yang digunakan	Output yang diharapkan
1	Menyiapkan data aktual (Data pengujian)	Dataset aktual hasil produksi pada periode pengujian	Data aktual yang siap digunakan
2	Menyiapkan hasil prediksi	Hasil prediksi model LSTM pada periode pengujian	Deret nilai prediksi untuk setiap timestamp pada test set
3	Menghitung residual kuadrat (SSR)	Nilai aktual y_i dan prediksi $\hat{y}_i$	Deret nilai residual kuadrat $(y_i - \hat{y}_i)^2$

4	Menghitung total variansi (SST)	Nilai aktual y_i dan prediksi $\bar{y}$	Deret nilai residual kuadrat $(y_i - \hat{y}_i)^2$ dan nilai $\sum (y_i - \bar{y}_i)^2$
5	Menghitung nilai R2 Score	$SSR = \sum (y_i - \hat{y})^2$ dan $SST = \sum (y_i - \bar{y})^2$	Nilai <i>R2 Score</i> . $R2\ Score = 1 - \frac{SSR}{SST}$

Keterangan:

$\hat{y}_i$: Nilai prediksi

y_i : Nilai aktual / Nilai sebenarnya

$\bar{y}_i$: Nilai rata-rata aktual

n : Jumlah data

Melalui evaluasi ini, diperoleh pemahaman kuantitatif mengenai kinerja model dalam merepresentasikan hubungan antara variabel input (seperti curah hujan dan pemupukan) terhadap hasil produksi kelapa sawit. Hasil evaluasi ini juga menjadi acuan dalam menentukan efektivitas model serta dalam melakukan perbaikan atau optimasi model pada tahap berikutnya.

3.5 Hasil yang diharapkan

Dari penelitian yang akan dilakukan ini, ada beberapa hasil yang diharapkan. Adapun hasil yang diharapkan antara lain:

1. Model dapat menghasilkan prediksi yang akurat mengenai hasil produksi kelapa sawit di PTPN IV REGIONAL 6 KSO menggunakan algoritma *Long Short-term Memory (LSTM)*.
2. Sistem membantu mengurangi waktu dan upaya manual yang sebelumnya diperlukan untuk memproses data time-series dan melakukan prediksi, sehingga mempercepat proses analisis dan pengambilan keputusan.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Implementasi Sistem

Pada Subbab ini membahas implementasi dari sistem yang sudah dirancang, berikut adalah hasil perancangan sistem yang berupa tampilan *User Interface* dari aplikasi *mobile* dan *website*.


4.4.1 Hasil Tampilan *User Interface*

Subbab ini akan memaparkan hasil tampilan antarmuka pengguna (*User Interface*) dari sistem prediksi hasil produksi kelapa sawit.

a. *User* Petugas Lapangan

1. Instalasi aplikasi *Prediction Oil Palm* di Android

Implementasi teknologi PWA yang berhasil diterapkan pada sistem. Untuk melihat *app Prediction Oil Palm* dapat dilihat pada Gambar 4.1.




Gambar 4. 1 Instalasi *App Prediction Oil* di *Mobile*

Proses *Progressive Web App* (PWA) dalam gambar ini melibatkan konversi aplikasi berbasis *website* yang diakses melalui URL `fe7861.ngrok-free.app` menjadi aplikasi yang dapat diinstal di perangkat *mobile*, seperti yang ditawarkan melalui *pop-up* untuk "*PredictionOilPalm*". PWA memanfaatkan teknologi *modern* seperti *service workers* untuk mendukung pengalaman *offline*, notifikasi *push*, dan akses cepat, memungkinkan pengguna menginstalnya langsung dari *browser* dengan opsi "*Instal*" tanpa perlu melalui toko aplikasi.

2. Halaman Login

Halaman Login dibuat untuk memvalidasi petugas lapangan sebelum memasuki halaman beranda pada aplikasi. Untuk melihat hasil tampilan dari Halaman Login dapat dilihat pada Gambar 4.2.




Gambar 4. 2 Halaman Login (Petugas Lapangan)

Menampilkan halaman login dari aplikasi *PredictionOilPalm* milik PTPN IV yang digunakan untuk sistem prediksi hasil produksi kelapa sawit.

3. Halaman Beranda

Halaman Beranda di rancang untuk *user* petugas lapangan melakukan penginputan data pemupukan dan hasil produksi. Untuk melihat Hasil tampilan dari Halaman Beranda, dapat dilihat pada Gambar 4.3.




Gambar 4. 3 Halaman Beranda (*Petugas Lapangan*)

Halaman utama dashboard aplikasi *Palm Oil Production* yang digunakan untuk mengelola dan memasukkan data produksi kelapa sawit. Di bagian atas terdapat status sistem yang aktif serta sambutan kepada pengguna. *Dashboard* ini menampilkan informasi ringkas seperti jumlah tahun tanam (6 tahun), jumlah blok (35 blok), jumlah pokok kelapa sawit (39.737), dan total produksi (52.717.911,18 kg) dengan indikator perubahan data. Terdapat dua tombol aksi utama yaitu "Tambah Data Pemupukan" dan "Tambah Data Produksi". Selain itu, ditampilkan juga daftar karyawan lapangan beserta jabatan dan lokasi kerja, tabel data blok yang mencakup nomor blok, tahun tanam, luas lahan, jumlah pokok, serta status kecukupan, dan bagian kosong untuk "Aktivitas Terkini".

b. User Admin

1. Halaman Login

Halaman Login Admin dibuat untuk memvalidasi user *Admin* untuk melakukan login sebelum memasuki halaman *Dashboard* aplikasi. Untuk melihat hasil tampilan Halaman Login dapat dilihat pada Gambar 4.4.




Gambar 4. 4 Halaman Login (Admin)

Menampilkan halaman login dari aplikasi, yang digunakan untuk mengakses sistem manajemen data produksi kelapa sawit. Pada halaman ini, pengguna diminta untuk memasukkan alamat email dan kata sandi untuk otentikasi, dengan tambahan opsi “Ingat saya” agar pengguna tetap masuk tanpa harus login ulang di kunjungan berikutnya. Tersedia juga ikon mata pada kolom kata sandi yang memungkinkan pengguna melihat atau menyembunyikan karakter sandi demi kenyamanan dan keamanan. Desain sederhana dan terfokus ini memastikan proses login berjalan cepat dan efisien bagi pengguna sistem.

2. Halaman *Dashboard*

Halaman *Dashboard* dirancang untuk *Admin* agar bisa melihat statistik dari data-data pada PTPN IV Regional 6 KSO Kebun Lama. Untuk melihat hasil tampilan dari Halaman *Dashboard*, dapat dilihat pada Gambar 4.5.




Gambar 4. 5 Halaman Dashboard (Admin)

Halaman dashboard yang menyajikan ringkasan statistik meliputi jumlah total blok (35), total produksi (1.069.999.172 kg) dengan peningkatan 15% dari bulan lalu, dan total luas lahan (1.413 ha) beserta produktivitasnya (757.253,48 kg/ha).

3. Halaman Afdeling

Halaman Afdeling dirancang untuk *Admin* agar bisa mengelola data karyawan, pemupukan, dan hasil produksi. Untuk melihat hasil tampilan dari Halaman *Dashboard*, dapat dilihat pada Gambar 4.6.



Gambar 4. 6 Halaman Afdeling (*Admin*)

Halaman *Afdeling* dari aplikasi *PTPN IV Oil Palm*, yang berfungsi untuk mengelola data berdasarkan unit kebun atau wilayah kerja yang disebut "Afdeling"

4. Halaman Dataset Sistem

Halaman Dataset Sistem dirancang untuk *Admin* agar bisa mengelola data Data pemupukan, curah hujan, dan hasil produksi yang telah dijumlahkan menjadi sebuah dataset. Untuk melihat hasil tampilan dari Halaman *Dashboard*, dapat dilihat pada Gambar 4.7.

☐	Tanggal	Total Curah Hujan (mm)	Total Pemupukan (kg)	Total Hasil Produksi (kg)	
☐	Jan 31, 2021	133,85		61.501.016	Ubah Hapus
☐	Feb 28, 2021	285,62	128.550,00	54.060.000	Ubah Hapus
☐	Mar 31, 2021	377,81	256.650,00	57.976.834	Ubah Hapus
☐	Apr 30, 2021	78,29	294.750,00	60.634.849	Ubah Hapus
☐	Mei 31, 2021	133,64	402.800,00	68.200.009	Ubah Hapus
☐	Jun 30, 2021	274,86	160.750,00	51.260.746	Ubah Hapus
☐	Jul 31, 2021	192,04	485.500,00	73.990.761	Ubah Hapus
☐	Agt 31, 2021	46,28	430.700,00	70.150.388	Ubah Hapus

Gambar 4. 7 Halaman Dataset Sistem (Admin)

Menampilkan desain *dashboard* Dataset Sistem untuk PTPN IV Oil Palm yang menawarkan tampilan data terstruktur terkait curah hujan, pemupukan, dan hasil produksi, dengan opsi untuk mengimpor, mengekspor, dan mengelola data. Desain ini menggunakan kombinasi warna yang kontras dan tata letak yang rapi, memungkinkan pengguna untuk dengan mudah memantau dan menganalisis informasi penting secara efisien.

5. Halaman Prediksi


Halaman Prediksi dirancang untuk *Admin* agar bisa melakukan prediksi hasil produksi pada bulan-bulan selanjutnya. Untuk melihat hasil tampilan dari Halaman *Dashboard*, dapat dilihat pada Gambar 4.8.

Gambar 4. 8 Halaman Prediksi (Admin)

Menampilkan halaman Hasil Prediksi yang sudah di generate dengan bulan yang ditentukan. Pada halaman ini menampilkan hasil prediksi yang dilakukan untuk bulan kedepannya.

6. Halaman Arsip Prediksi

Halaman Arsip Prediksi dirancang untuk *Admin* agar bisa melihat histori hasil prediksi yang sudah generate. Untuk melihat hasil tampilan dari Halaman Arsip Prediksi, dapat dilihat pada Gambar 4.9.




Gambar 4. 9 Halaman Hasil Prediksi (*Admin*)

Menampilkan halaman Hasil Prediksi dari aplikasi, yang berisi output hasil prediksi produksi kelapa sawit berdasarkan data *time series* yang telah dianalisis sebelumnya.

c. User Manager

1. Laporan

Halaman Laporan untuk *Manager* agar bisa melihat hasil dari keseluruhan data agar bisa mengambil keputusan lanjutan. Untuk melihat hasil tampilan dari Halaman Laporan, dapat dilihat pada Gambar 4.10.



Gambar 4. 10 Halaman Laporan (Manager)

Menampilkan desain dashboard laporan komprehensif untuk *Portal Manager* PTPN IV Kebun Lama, yang menawarkan akses langsung ke data langsung dan laporan per afdeling dengan tata letak yang intuitif. Desain ini menggunakan kombinasi warna cerah dan elemen visual yang menarik untuk menyajikan

informasi seperti total blok aktif dan pohon kelapa, memberikan pengalaman pengguna yang informatif dan mudah dinavigasi.

4.2 Pengelolaan Data


Pada subbab ini, dibahas mengenai proses pengelolaan data yang meliputi pengumpulan, pemrosesan, dan visualisasi data faktor lingkungan, faktor perawatan, dan hasil produksi.

a. Faktor lingkungan

Pengumpulan data ini dilakukan melalui *website Google Earth Engine*, yang memungkinkan ekstraksi data raster secara otomatis berdasarkan koordinat geografis spesifik. Menggunakan *script python* yang dirancang untuk mengkonfigurasi *CHIRPS Daily*, serta mendefinisikan wilayah studi (*Region of Interest/ROI*). Berikut langkah-langkah pengambilan data curah hujan:

1. Proses pengambilan data curah hujan

Pengambilan data curah menggunakan *Google Earth Engine CHIRPS Daily* dapat dilihat pada Gambar 4.11.




Gambar 4. 11 *Google Earth Engine CHIRPS Daily*

Menunjukkan antarmuka *Google Earth Engine* dengan script Python yang mendefinisikan ROI berupa poligon di wilayah Aceh Tamiang. *Script* tersebut melakukan reduksi data curah hujan harian dari dataset *CHIRPS Daily*,

menghasilkan seri waktu yang divisualisasikan dalam bentuk grafik batang sederhana di panel kanan. Peta di bagian bawah menggambarkan lokasi spesifik dengan overlay data.

2. Grafik *chart* data curah hujan

Data curah hujan dalam bentuk grafik *chart* yang dihasilkan dari *script python* di area Aceh Tamiang dapat dilihat pada Gambar 4.12.



Gambar 4. 12 Grafik *chart* data curah hujan

Sampel data curah hujan harian yang dihasilkan dari *script python* menggunakan *Google Earth Engine CHIRPS Daily* dapat dilihat pada Tabel 4.1.

Tabel 4. 1 Sampel data curah hujan harian

Time	Precipitation
Dec 17, 2023	11.9
Dec 18, 2023	11.9
Dec 19, 2023	0
Dec 20, 2023	0
Dec 21, 2023	0
Dec 22, 2023	0
Dec 23, 2023	15.9
Dec 24, 2023	63.8
Dec 25, 2023	15.9
Dec 26, 2023	9.9
Dec 17, 2023	11.9
Dec 18, 2023	11.9
Dec 19, 2023	0

Data curah hujan diambil menggunakan *script python* dengan mengintegrasikan *Google Earth Engine Catalog CHIRPS Daily*, kemudian menentukan koordinat dengan menyeleksi bagian daerah Aceh Tamiang. Dari Tabel 4.1, dapat diamati bahwa nilai curah hujan berkisar antara 0 hingga 63.8 mm per hari dalam periode 2005-2024, mencerminkan pola musiman yang memengaruhi pertumbuhan kelapa sawit.

3. Mejumlahkan data curah hujan harian menjadi bulanan

Data curah hujan harian yang sudah didapatkan, kemudian diubah menjadi data curah hujan bulanan menggunakan *script python* yang bisa dilihat pada Lampiran 2. Sampel data curah hujan bulanan dapat dilihat pada Tabel 4.2.

Tabel 4. 2 Sampel data curah hujan bulanan

Time	precipitation
2021-01	344.122
2021-02	102.521
2021-03	192.932
2021-04	168.518
2021-05	129.157
2021-06	154.926
2021-07	141.636
2021-08	342.601
2021-09	137.755
2021-10	236.08
2021-11	366.175
2021-12	301.078

Sampel data curah hujan bulanan untuk tahun 2021, dengan kolom “*Time*” menunjukkan periode bulan dan “*Precipitation*” merepresentasikan total curah hujan kumulatif dalam milimeter (mm).

b. Faktor lingkungan

Data yang digunakan pada faktor perawatan yaitu data pemupukan. Contoh data pemupukan yang diambil langsung dari perusahaan PTPN IV Regional 6 (KSO) dengan parameter yang akan digunakan adalah tahun tanam, no blok, luas lahan (Ha), jumlah pokok, dosis pupuk, dan volume (Kg). Contoh data dapat dilihat pada Tabel 4.3.

Tabel 4. 3 Data Pemupukan

JENIS	RENCANA	REAL													
		JAN	FEB	MAR	APR	MEI	JUN	JUL	AGS	SEPT	OKT	NOV	DES	JUMLAH	% Real vs Rekomendasi
Dolomite	630,650		52,200	417,400	115,450		45,600				-			630,650	100.00
NPK	2,101,760				203,150	491,950	796,950		146,200		-			1,638,250	77.95
Bioneensis	467,700				21,350	40,000	406,350				-			467,700	100.00
Urea	447,108								1,650		-			1,650	0.37
MOP	249,707								13,085		236,631			249,716	100.00
Borate	28,314									274	-	2,358		2,632	9.30

Data pemupukan, yang dimana pemupukan dilakukan pada tiap-tiap blok dengan waktu pelaksanaanya 3 bulan sekali. Pada penelitian ini parameter atau atribut yang digunakan terdiri dari luas, jumlah pokok, dosis, dan volume.

c. Hasil Produksi

Data hasil produksi merupakan data utama yang digunakan dalam memprediksi hasil produksi nantinya. Contoh data Hasil Produksi yang diambil langsung dari perusahaan PTPN IV Regional 6 (KSO) dengan parameter yang akan digunakan adalah dapat dilihat pada Tabel 4.4.

Tabel 4. 4 Data Hasil Produksi

AFD	Luas (Ha)	Jumlah Kg Produksi			
		Rencana		Realisasi	
		B.I	S/D	B.I	S/D
I	512.0	635,000	8,976,000	626,870	7,271,180
II	858.7	1,346,000	19,930,000	1,486,370	17,610,390
III	759.0	1,215,000	18,308,000	1,334,010	16,580,120
IV	524.8	778,000	11,495,000	689,310	9,728,090
V	523.6	819,000	12,093,000	708,570	10,228,860
VI	117.4	121,000	1,789,000	140,900	1,639,760
Jumlah	3,295.5	4,914,000	72,591,000	4,986,030	63,058,400

Data hasil produksi, yang dimana data tersebut merupakan data produksi harian, yang mencakup atribut prod (produksi) dan BRD (brondolan). Pada penelitian ini, parameter atau atribut data yang digunakan hanya atribut data produksi.

4.3 Implementasi Model

Penelitian ini ini menggunakan Dataset yang terdiri dari 250 data. Pembangunan Model LSTM dilakukan melalui beberapa prosedur yang dijelaskan di bab 3. Berikut adalah implementasi dari setiap prosedur tersebut.

4.2.1 Cleaning Data

Clean Data digunakan untuk membersihkan dan menyiapkan data sebelum digunakan dalam pelatihan model. Proses ini mencakup pengisian nilai yang hilang (*NaN*) dengan metode *forward fill* dan *backward fill* agar urutan data tetap utuh, menghapus baris yang masih mengandung nilai kosong setelah proses

pengisian, serta menghilangkan data duplikat agar tidak memengaruhi hasil pelatihan. Hasil dari proses *Clean Data* dapat dilihat pada Gambar 4.13.

	curah_hujan	pemupukan	hasil_produksi
tanggal			
2005-01-31	236.00	1124604.0	69531612
2005-02-28	569.61	790813.0	66712636
2005-03-31	442.97	423612.0	65712100
2005-04-30	365.77	436324.0	68021283
2005-05-31	109.47	906757.0	69347719
...	...	...	...
2024-08-31	139.19	160935.0	64336742
2024-09-30	19.13	274.0	57145727
2024-10-31	61.09	236631.0	62516380
2024-11-30	306.11	2358.0	73305893
2024-12-31	221.70	2358.0	78395388

Gambar 4. 13 Hasil *Cleaning Data*

Menunjukkan *output* dari *DataFrame* yang telah dibersihkan. Output ini berisi 240 baris dan 4 kolom, yaitu bulan, curah_hujan, pemupukan, dan hasil_produksi, yang masing-masing merepresentasikan data bulanan dari Januari 2005 hingga Desember 2024. Berdasarkan hasil pembersihan, seluruh nilai kosong (jika ada) telah ditangani dengan *forward fill* dan *backward fill*, serta seluruh duplikasi baris telah dihapus dan indeks direset. Hasil akhirnya adalah *DataFrame* yang bersih, lengkap, dan siap digunakan untuk pelatihan model *machine learning* seperti *LSTM* tanpa ada gangguan dari data kosong atau duplikat.

4.2.2 Normalisasi Data

Normalisasi data adalah proses mengubah skala nilai-nilai fitur agar berada dalam rentang tertentu, dengan tujuan untuk meningkatkan kinerja dan stabilitas algoritma machine learning. Salah satu metode normalisasi yang umum digunakan adalah *MinMaxScaler*, yang mengubah data ke dalam rentang [0, 1]

(atau rentang lain yang ditentukan). Hasil dari proses Normalisasi Data dapat dilihat pada Gambar 4.14.

	curah_hujan	pemupukan	hasil_produksi
tanggal			
2005-01-31	0.374547	0.900418	0.559627
2005-02-28	0.950710	0.633102	0.462566
2005-03-31	0.731995	0.339030	0.428116
2005-04-30	0.598667	0.349210	0.507624
2005-05-31	0.156022	0.725955	0.553295
...	...	...	...
2024-08-31	0.207350	0.128665	0.380760
2024-09-30	0.000000	0.000000	0.133164
2024-10-31	0.072467	0.189286	0.318083
2024-11-30	0.495631	0.001669	0.689580
2024-12-31	0.349850	0.001669	0.864819

Gambar 4. 14 Hasil Normalisasi Menggunakan *MinMaxScaler*

Proses normalisasi menggunakan kode tersebut adalah data `x_scaled` dan `y_scaled` yang telah dikonversi ke dalam rentang nilai antara 0 hingga 1. Proses ini dilakukan dengan menggunakan *MinMaxScaler*, yang menghitung skala berdasarkan nilai minimum dan maksimum dari setiap fitur secara terpisah untuk data input (x) dan target/output (y). Tujuan normalisasi ini adalah untuk memastikan bahwa semua fitur memiliki skala yang seragam, sehingga model LSTM dapat belajar lebih efektif dan stabil, tanpa bias terhadap fitur dengan nilai yang lebih besar.

4.2.3 Pembangunan Model *LSTM (Long Short-term Memory)*

Model *Long Short-Term Memory* (LSTM) yang dirancang untuk penelitian ini memiliki arsitektur yang disesuaikan untuk memproses data deret waktu (curah hujan, pemupukan, dan produksi) dan mempelajari ketergantungan jangka panjang di antara data tersebut. Arsitektur model terdiri dari beberapa lapisan utama yang bekerja secara sekuensial. Lapisan LSTM pertama berfungsi untuk mengekstraksi fitur dan pola temporal dari data input, seperti dampak curah hujan

dan pemupukan beberapa bulan lalu terhadap produksi saat ini. Hasil finte tuning dari arsitektur model LSTM dapat dilihat pada Gambar 4.15.

Model: "sequential_1"		
Layer (type)	Output Shape	Param #
lstm_2 (LSTM)	(None, 12, 128)	67584
dropout_2 (Dropout)	(None, 12, 128)	0
lstm_3 (LSTM)	(None, 64)	49408
dropout_3 (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 1)	65
=====		
Total params: 117057 (457.25 KB)		
Trainable params: 117057 (457.25 KB)		
Non-trainable params: 0 (0.00 Byte)		

Gambar 4. 15 Layer Model Yang digunakan

Menunjukkan arsitektur model LSTM *Sequential* yang terdiri dari dua lapisan LSTM dan dua lapisan Dropout untuk memproses data time series dengan 12 timesteps (*look_back*=12) dan 2 fitur input. Lapisan LSTM pertama memiliki 128 unit dengan *return_sequences=True* untuk mempertahankan urutan waktu dan menghasilkan output berbentuk *(None, 12, 128)*, diikuti oleh *Dropout* 20% untuk regularisasi. Lapisan LSTM kedua memiliki 64 unit dengan *return_sequences=False* untuk mengembalikan hanya *output* akhir berbentuk *(None, 64)*, lalu dilanjutkan dengan *Dropout* 20% lagi.

4.4 Hasil Pengujian

Pada Subbab ini membahas 3 pengujian yang dilakukan pada sistem, yaitu pengujian kinerja Model, *White Box*, dan *Black Box*.

4.3.1 Hasil Pengujian *Black Box*

Tabel di bawah ini menampilkan hasil pengujian *black box* menggunakan *framework Laravel*. Pengujian ini mencakup pengujian ini mencakup fitur-fitur seperti *Login*, *Prediksi*, *Lihat Arsip Prediksi*, *Input data pemupukan* dan hasil produksi oleh petugas lapangan, dan *Logout*.

1. Pengujian Halaman Login *Admin*

Halaman Login dirancang untuk memberikan akses kepada *user* agar dapat mengakses halaman-halaman tertentu, pada tahapan ini pengujian akan dilakukan pada Halaman Login *Admin*. Untuk melihat pengujian halaman Login *Admin* bisa dilihat pada Tabel 4.5.

Tabel 4. 5 Pengujian Halaman Login *Admin*

TEST CASE ID	FITUR	TEST CASE	PERCONDITION	TEST STEP	TEST DATA	EXPECTED RESULT	ACTUAL RESULT	STATUS
L1_01	Login	User <i>Admin</i> login dengan username benar dan passowrd benar	Berada pada form login	1. Input Username 2. Input Password 3. Klik tombol log in	Username dan Password	User berhasil masuk ke halaman dashboard	User berhasil masuk ke halaman dashboard	LULUS
L1_02		User <i>Admin</i> login dengan username benar dan password salah	Berada pada form login	1. Input Username 2. Input Password 3. Klik tombol log in	Username dan Password	Menampilkan notif “username/pass word salah” dan tetap berada di halaman login	Menampilkan notif “username/pass word salah” dan tetap berada di halaman login	LULUS
L1_03		User <i>Admin</i> login dengan username salah dan password benar	Berada pada form login	1. Input Username 2. Input Password 3. Klik tombol log in	Username dan Password	Menampilkan notif “username/pass word salah” dan tetap berada di halaman login	Menampilkan notif “username/pass word salah” dan tetap berada di halaman login	LULUS

L1_04		User <i>Admin</i> login dengan username salah dan password salah	Berada pada form login	1. Input Username 2. Input Password 3. Klik tombol log in	Username dan Password	Menampilkan notif “username/password salah” dan tetap berada di halaman login	Menampilkan notif “username/password salah” dan tetap berada di halaman login	LULUS
-------	--	--	------------------------	---	-----------------------	---	---	-------

2. Pengujian Halaman Login Petugas Lapangan

Halaman Login dirancang untuk memberikan akses kepada user agar dapat mengakses halaman-halaman tertentu, pada tahapan ini pengujian akan dilakukan pada Halaman Login Petugas Lapangan. Untuk melihat pengujian halaman Login Petugas Lapangan, bisa dilihat pada Tabel 4.6.

Tabel 4. 6 Pengujian Halaman Login *Petugas Lapangan*

TEST CASE ID	FITUR	TEST CASE	PERCONDITION	TEST STEP	TEST DATA	EXPECTED RESULT	ACTUAL RESULT	STATUS
L1_01	Login	User Petugas Lapangan login dengan username benar dan password benar	Berada pada form login	1. Input Username 2. Input Password 3. Klik tombol log in	Username dan Password	User berhasil masuk ke halaman dashboard	User berhasil masuk ke halaman dashboard	LULUS

L1_02		User Petugas Lapangan login dengan username benar dan password salah	Berada pada form login	1. Input Username 2. Input Password 3. Klik tombol log in	Username dan Password	Menampilkan notif “username/password salah” dan tetap berada di halaman login	Menampilkan notif “username/password salah” dan tetap berada di halaman login	LULUS
L1_03		User Petugas Lapangan login dengan username salah dan password benar	Berada pada form login	1. Input Username 2. Input Password 3. Klik tombol log in	Username dan Password	Menampilkan notif “username/password salah” dan tetap berada di halaman login	Menampilkan notif “username/password salah” dan tetap berada di halaman login	LULUS
L1_04		User Petugas Lapangan login dengan username salah dan password salah	Berada pada form login	1. Input Username 2. Input Password 3. Klik tombol log in	Username dan Password	Menampilkan notif “username/password salah” dan tetap berada di halaman login	Menampilkan notif “username/password salah” dan tetap berada di halaman login	LULUS

3. Pengujian Halaman Prediksi *Admin*

Halaman Prediksi dirancang untuk melakukan prediksi hasil produksi kelapa sawit, prediksi yang dilakukan adalah prediksi untuk bulan kedepan. Pada tahapan ini, akan dilakukan pengujian untuk halaman prediksi. Untuk melihat hasil pengujian halaman prediksi dapat dilihat pada Tabel 4.7.

Tabel 4. 7 Pengujian Halaman Prediksi *Admin*

TEST CASE ID	FITUR	TEST CASE	PERCOND ITION	TEST STEP	TEST DATA	EXPECTED RESULT	ACTUAL RESULT	STATUS
PP_01	Prediksi	User <i>Admin</i> menginput bulan dan tahun yang ingin diprediksi	Berada pada halaman prediksi	1. Input Bulan 2. Input Tahun 3. Klik tombol prediksi	Bulan dan Tahun yang ingin di prediksi	Menampilkan Hasil prediksi pada Bulan dan tahun yang diinginkan, serta menampilkan data Historikal 6 bulan sebelumnya yang digunakan untuk prediksi	Menampilkan Hasil prediksi pada Bulan dan tahun yang diinginkan, serta menampilkan data Historikal 6 bulan sebelumnya yang digunakan untuk prediki	LULUS
PP_02		User <i>Admin</i> menginput bulan dan tahun sebelumnya	Berada pada halaman prediksi	1. Input Bulan 2. Input Tahun 3. Klik tombol prediksi	Bulan dan Tahun sebelumnya	Menampilkan Notifikasi "Error Bulan/tahun target harus lebih baru dari data <i>time series</i> ."	Menampilkan Notifikasi "Error Bulan/tahun target harus lebih baru dari data historis."	LULUS
PP_03		User <i>Admin</i> menginput Bulan depan dan Tahu Saat ini	Berada pada halaman prediksi	1. Input Bulan Depan 2. Input Tahun Saat ini 3. Klik tombol prediksi	Bulan depan dan Tahun saat ini	Menampilkan Hasil prediksi pada Bulan dan tahun yang diinginkan, serta menampilkan data Historikal 6 bulan sebelumnya yang digunakan untuk prediksi	Menampilkan Hasil prediksi pada Bulan dan tahun yang diinginkan, serta menampilkan data Historikal 6 bulan sebelumnya yang digunakan untuk prediksi	LULUS

4. Pengujian Input Data Pemupukan dan Hasil Produksi halaman beranda *Petugas Lapangan*

Halaman beranda dirancang untuk *user petugas lapangan* melakukan inputan data pemupukan dan hasil produksi. Pada tahapan ini, dilakukan pengujian pada halaman beranda untuk melihat fitur inputan pemupukan dan hasil produksi berfungsi dengan baik atau tidak. Untuk melihat hasil dari pengujian halaman beranda, dapat dilihat pada Tabel 4.11.

Tabel 4. 8 Pengujian Input Data Pemupukan dan Hasil Produksi Petugas Lapangan

TEST CASE ID	FITUR	TEST CASE	PERCONDITION	TEST STEP	TEST DATA	EXPECTED RESULT	ACTUAL RESULT	STATUS
PH_01	Input Data Pemupukan	User Melakukan penginputan Data Pemupukan	Berada oada Halaman Beranda <i>Petugas Lapangan</i>	1. Input Tanggal 2. Input Blok 3. Input Dosis Pupuk 4. Input Volume Pupuk 5. Tombol Submit	Tanggal "08/07/2025", Blok "ST.65", Dosis "20", Volume "104"	Menampilkan Notifikasi "Berhasil - Data Pemupukan berhasil ditambah"	Menampilkan Notifikasi "Berhasil - Data Pemupukan berhasil ditambah"	LULUS
PH_02	Input Data Hasil Produksi	User Melakukan penginputan Data Hasil Produksi	Berada oada Halaman Beranda <i>Petugas Lapangan</i>	1. Input Tanggal 2. Input Blok 3. Input Hasil Produksi 4. Tombol Submit	Tanggal "08/07/2025", Blok "ST.65", Produksi "1807"	Menampilkan Notifikasi "Berhasil - Data Hasil Produksi berhasil ditambah"	Menampilkan Notifikasi "Berhasil - Data Hasil Produksi berhasil ditambah"	LULUS

5. Pengujian *Logout*

Halaman *Logout* dirancang untuk agar *user* bisa keluar dari aplikasi. Pada tahapan ini, dilakukan pengujian untuk melihat fitur *logout* berfungsi dengan baik atau tidak. Untuk melihat hasil pengujian Halaman *Logout*, dapat dilihat pada Tabel 4.12.

Tabel 4. 9 Pengujian *Logout*


TEST CASE ID	FITUR	TEST CASE	PERCONDITION	TEST STEP	TEST DATA	EXPECTED RESULT	ACTUAL RESULT	STATUS
LO_01	<i>Logout</i>	User <i>Admin</i> melakukan <i>Logout</i> pada Aplikasi	User sudah melakukan Login	Admin menekan avatar profil	Tombol <i>Logout</i>	Berhasil <i>Logout</i> dan redirect ke halaman Login	Berhasil <i>Logout</i> dan redirect ke halaman Login	LULUS

4.3.2 Evaluasi Model dengan *MAE*, *RMSE*, dan *R² Score*

Pada Bagian ini, pengujian dilakukan menggunakan data *training* dan *testing* untuk mengevaluasi performa model LSTM dengan tiga metrik yaitu MAE, RMSE, dan *R² Score*.

1. Evaluasi *Training*

Hasil Evaluasi *Testing* dari model LSTM dapat dilihat pada Gambar 4.16.



(a) Data Prediksi vs Aktual *Training*

(b) Evaluasi Matriks *Training*


Gambar 4. 16 Grafik Hasil Evaluasi Training

Hasil evaluasi training pada model *Long Short-Term Memory* (LSTM) untuk prediksi hasil produksi kelapa sawit di PTPN IV Regional 6 KSO mencakup grafik perbandingan antara nilai aktual (garis biru solid) dan prediksi (garis merah putus-putus), beserta metrik evaluasi. Grafik tersebut mengilustrasikan bahwa prediksi model mengikuti pola tren dengan indeks waktu 0 hingga 175 yang merepresentasikan 184 data *training* (184 bulan). Metrik evaluasi menunjukkan *Root Mean Square Error* (RMSE) sebesar 2.478.653, *Mean Absolute Error* (MAE) sebesar 1.961.861, serta koefisien determinasi *R² Score* sebesar 0.86, yang mengindikasikan bahwa model mampu menjelaskan 86% variabilitas dalam data training. Temuan ini mencerminkan kemampuan model dalam menangkap pola time series, meskipun 14% variabilitas yang tidak terjelaskan dapat disebabkan oleh variabilitas tinggi pada data produksi. Hasil tersebut menunjukkan performa yang baik pada fase *training*, tetapi menyoroti potensi peningkatan melalui

penambahan variabel tambahan atau optimalisasi hiperparameter untuk mengurangi kesalahan pada dataset yang lebih kompleks.

2. Evaluasi *Testing*

Hasil Evaluasi *Testing* dari model LSTM dapat dilihat pada Gambar 4.17.



(a) Data Prediksi vs Aktual *Testing*

(b) Evaluasi Matriks *Testing*


Gambar 4. 17 Grafik Hasil Evaluasi Testing Model

Evaluasi testing pada model *Long Short-Term Memory* (LSTM) untuk prediksi hasil produksi kelapa sawit di PTPN IV Regional 6 KSO menghasilkan performa yang dapat diukur melalui grafik perbandingan antara nilai aktual (garis biru solid) dan prediksi (garis merah putus-putus), dengan indeks waktu dari 0 hingga 40 yang merepresentasikan 44 data *testing* (44 bulan). Rentang nilai produksi pada grafik tersebut berkisar antara sekitar 50 hingga 85 juta unit. Grafik evaluasi di sisi kanan menampilkan metrik *Root Mean Square Error* (RMSE) sebesar 2.833.346, yang mengindikasikan tingkat kesalahan rata-rata kuadrat. *Mean Absolute Error* (MAE) sebesar 1.967.065, yang merefleksikan kesalahan absolut rata-rata. *R2 Score* sebesar 0.81, yang menunjukkan bahwa model mampu menjelaskan 81% variabilitas dalam data testing. Hasil ini menunjukkan kemampuan model dalam menangkap pola tren *time series*, meskipun variabilitas tinggi pada data produksi dapat memengaruhi presisi. Sebanyak 19% variabilitas yang tidak dijelaskan menyoroti potensi perbaikan, seperti penambahan variabel

tambahan atau optimalisasi hiperparameter, untuk meningkatkan generalisasi model pada dataset serupa.

3. Perbandingan evaluasi *testing* dan *training*

Hasil perbandingan dari evaluasi *testing* dan evaluasi *training* dari model LSTM dapat dilihat pada Gambar 4.18 .



Gambar 4. 18 Perbandingan evaluasi testing dan training

Perbandingan metrik evaluasi antara fase *training* dan *testing* pada model *Long Short-Term Memory* (LSTM) untuk prediksi hasil produksi kelapa sawit di PTPN IV Regional 6 KSO. Diagram ini menampilkan tiga metrik yaitu *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan koefisien determinasi *R2 Score*, dengan warna biru tua merepresentasikan nilai *training* dan oranye merepresentasikan nilai *testing*. Sumbu *horizontal* mengelompokkan metrik, sementara sumbu vertikal menunjukkan skala nilai (untuk RMSE dan MAE dalam satuan jutaan kg, serta *R2 Score* dalam rentang 0-1). Secara spesifik, nilai RMSE pada *training* sebesar 2.478.653, sedangkan pada *testing* meningkat menjadi 2.833.346, mengindikasikan peningkatan kesalahan rata-rata kuadrat. Demikian

pula, MAE pada training mencapai 1.961.861 dan sedikit meningkat menjadi 1.967.065 pada testing, mencerminkan kesalahan absolut rata-rata yang relatif stabil. Untuk R^2 Score, nilai training sebesar 0.86 menurun menjadi 0.81 pada testing, yang menunjukkan bahwa model mampu menjelaskan 86% variabilitas data selama training, tetapi hanya 81% pada testing. Hasil ini mengilustrasikan performa model yang konsisten tanpa indikasi overfitting signifikan, karena perbedaan nilai antar fase relatif kecil. Namun, penurunan R^2 Score dan peningkatan RMSE/MAE pada testing menyiratkan pengaruh variabilitas data produksi, seperti fluktuasi musiman akibat faktor lingkungan dan perawatan.

a. Evaluasi *Testing* MAE


Sampel hasil perbandingan nilai angka pada data produksi dan data prediksi dengan satuan kg ketika dilakukan evaluasi menggunakan matrik MAE dapat dilihat pada Tabel 4.10.

Tabel 4. 10 Nilai Evaluasi *Testing* MAE

Aktual	Prediksi	Selisih Absolut
69.183.816	70.919.600	1.735.784
61.067.971	62.017.144	949.173
58.071.403	58.012.276	59.127
62.118.864	68.629.890	6.511.026
72.602.135	73.392.800	790.665
76.401.201	74.261.690	2.139.511
Rata-rata Nilai Aktual		69.854.418
Total Kesalahan Absolut		86.550.852
Jumlah Data		44
MAE		1.967.065


Visualisasi perbandingan antara nilai aktual, prediksi, dan selisih absolut untuk sampel data dapat dilihat pada Gambar 4.19. Grafik ini mengilustrasikan bahwa nilai prediksi secara umum mendekati nilai aktual, meskipun terdapat variasi selisih absolut yang lebih besar pada titik data tertentu (misalnya, Data

4 dengan selisih tertinggi), yang menunjukkan adanya potensi outlier dalam prediksi.



Gambar 4. 19 Perbandingan data aktual, prediksi, dan selisih

Selanjutnya, perbandingan antara nilai MAE dan rata-rata nilai aktual disajikan pada Gambar 4.20. Grafik ini menekankan bahwa MAE relatif kecil dibandingkan dengan rata-rata nilai aktual, mengonfirmasi tingkat kesalahan prediksi yang rendah secara proporsional.



Gambar 4. 20 Perbandingan nilai MAE dan rata-rata nilai aktual

Evaluasi kinerja model prediksi menunjukkan hasil yang menjanjikan, dengan nilai *Mean Absolute Error* (MAE) sebesar 1.967.065. Nilai MAE ini dihitung sebagai rata-rata dari total kesalahan absolut sebesar 86.550.852 yang terdistribusi pada 44 titik data, merepresentasikan selisih rata-rata absolut antara nilai prediksi dan nilai aktual. Kinerja ini dapat dianggap baik, karena kesalahan prediksi rata-rata hanya sekitar 3% dari rata-rata nilai aktual sebesar 69.854.418.


b. Evaluasi *Testing* RMSE

Sampel hasil perbandingan nilai angka pada data produksi dan data prediksi ketika dilakukan evaluasi menggunakan matrik RMSE dapat dilihat pada Tabel 4.6.

Tabel 4. 11 Nilai Evaluasi *Testing* RMSE


Aktual	Prediksi	Selisih	Error
69.183.816	70.919.600	-1.735.784	3.012.946.094.656
61.067.971	62.017.144	-949.173	900.929.383.929
58.071.403	58.012.276	59.127	3.496.002.129
62.118.864	68.629.890	-6.511.026	42.393.459.572.676
72.602.135	73.392.800	-790.665	625.151.142.225
76.401.201	74.261.690	2.139.511	4.577.507.319.121
Rata-rata Nilai Aktual			69.854.418
Total Kuadrat Error			353.225.553.654.007
Rata-rata Kuadrat Error			8.027.853.492.137
RMSE			2.833.347

Visualisasi perbandingan antara nilai aktual, prediksi, dan selisih absolut untuk sampel data dapat dilihat pada Gambar 4.21. Grafik ini menunjukkan bahwa nilai prediksi umumnya mendekati nilai aktual, meskipun terdapat variasi selisih absolut yang lebih signifikan pada beberapa titik data (misalnya, Data 4 dengan selisih absolut tertinggi).



Gambar 4. 21 Perbandingan data aktual, prediksi, dan selisih

Selanjutnya, perbandingan antara nilai RMSE dan rata-rata nilai aktual disajikan pada Gambar 4.22. Grafik ini mengilustrasikan bahwa RMSE relatif kecil dibandingkan dengan rata-rata nilai aktual, menegaskan bahwa kesalahan prediksi berada pada tingkat yang dapat diterima.



Gambar 4. 22 Perbandingan nilai RMSE dan rata-rata nilai aktual

Evaluasi model prediksi menggunakan metrik *Root Mean Squared Error* (RMSE) sebesar 2.833.347, dihitung dari total kuadrat error

353.225.553.654.007 untuk 44 data, dengan rata-rata kuadrat error 8.027.853.492.137. RMSE yang lebih tinggi dari MAE (1.634.711,77) menunjukkan bahwa model sensitif terhadap kesalahan besar, karena RMSE memberi bobot lebih pada kesalahan besar melalui pengkuadratan. Meski demikian, RMSE ini relatif kecil dengan persentase yang didapatkan sebesar 4% dari rata-rata nilai aktual 69.854.418, meskipun ada potensi peningkatan untuk mengurangi kesalahan besar.

c. Evaluasi *Testing R² Score*

Sampel hasil perbandingan nilai angka pada data produksi dan data prediksi ketika dilakukan evaluasi menggunakan matrik *R² Score* dapat dilihat pada Tabel 4.7.

Tabel 4. 12 Nilai Evluasi *Testing RMSE*

Aktual	Prediksi	Rata-rata Aktual	SS Resedual	SS Total
69.183.816	70.919.600	66.574.232	3.012.946.094.656	6.809.930.392.779
61.067.971	62.017.144	66.052.315	900.929.383.929	24.843.683.116.599
58.071.403	58.012.276	67.298.401	3.496.002.129	85.137.487.478.505
62.118.864	68.629.890	70.374.067	42.393.459.572.676	68.148.371.067.741
72.602.135	73.392.800	74.501.668	625.151.142.225	3.608.225.618.089
76.401.201	74.261.690	76.401.201	4.577.507.319.121	0
Jumlah			353.225.553.654.007	1.784.138.929.448.540
R2 Score			0,80	

Evaluasi model prediksi menggunakan metrik *R² Score* sebesar **0,80**, yang menunjukkan bahwa 80% variabilitas data aktual dapat dijelaskan oleh model prediksi. Dari 6 sampel data, nilai aktual (58 juta hingga 76 juta) dibandingkan dengan prediksi, dengan SS Residual (jumlah kuadrat selisih prediksi dan aktual) sebesar 220.186.833.337.319 dan SS Total (jumlah kuadrat selisih aktual dan rata-rata aktual) sebesar 1.784.138.929.448.540. *R² Score* menghasilkan nilai 0,88, yang menunjukkan performa model yang baik, meskipun tidak sempurna. Nilai ini mengindikasikan bahwa model cukup efektif dalam menangkap pola data produksi, seperti hasil panen atau

penjualan, tetapi masih ada 12% variabilitas yang tidak dijelaskan, kemungkinan karena kesalahan besar pada beberapa titik data (misalnya, selisih 3.087.992 pada sampel ke-4). Dengan skala data yang besar, R^2 Score 0,88 menunjukkan model yang andal, tetapi ada ruang untuk perbaikan guna meningkatkan akurasi prediksi.

BAB V

KESIMPULAN

5.1 Kesimpulan

Dari hasil penelitian dapat disimpulkan bahwa model *Long Short-Term Memory* (LSTM) yang digunakan dirancang secara spesifik untuk memprediksi data deret waktu (*time series*) produksi kelapa sawit dengan tingkat akurasi tinggi. Model ini memiliki dua lapisan LSTM dengan 128 dan 64 unit yang berurutan dan menggunakan fungsi aktivasi relu untuk menangkap dependensi jangka panjang. Untuk mencegah *overfitting*, setiap lapisan LSTM diikuti oleh lapisan *dropout* dengan probabilitas 0.2. Model diakhiri dengan dua lapisan *Dense*, di mana lapisan pertama memiliki 32 unit dengan fungsi aktivasi relu dan lapisan *output* memiliki 1 unit dengan fungsi aktivasi *linear*. Proses pelatihan model ini dilakukan selama 200 *epochs* menggunakan ukuran *batch* 32 dan dioptimalkan dengan algoritma *Adam*, serta memanfaatkan fungsi kerugian *Mean Squared Error* (MSE) untuk mengukur performa.

Evaluasi model menggunakan metrik *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan *R² Score* mengonfirmasi efektivitasnya. Hasil evaluasi menunjukkan nilai MAE sebesar 1.967.065, yang merefleksikan kesalahan absolut prediksi hanya sekitar 3% dari rata-rata nilai aktual (69.854.418). Selanjutnya, nilai RMSE tercatat sebesar 2.833.346, menunjukkan kesalahan kuadrat rata-rata yang relatif kecil, yaitu sekitar 4% dari rata-rata nilai aktual (69.854.418). Dengan *R² Score* sebesar 0.81, model ini mampu menjelaskan 81% variabilitas data produksi, menandakan bahwa variabilitas data produksi dapat dijelaskan oleh model ini dengan tingkat kesalahan prediksi yang rendah. Secara keseluruhan, hasil evaluasi ini mengonfirmasi bahwa performa model LSTM layak dan akurat dalam memprediksi hasil produksi dengan tingkat kesalahan yang rendah dan kemampuan yang baik dalam menjelaskan pola data.

Pengujian *black box* pada sistem prediksi produksi kelapa sawit menggunakan model LSTM dinyatakan lulus karena seluruh fitur utama seperti *login*, prediksi, *input* data, dan *logout* berfungsi sesuai ekspektasi tanpa kegagalan

atau anomali, memastikan sistem stabil dan siap digunakan oleh pengguna akhir. Status "lulus" dalam konteks ini berarti sistem memenuhi kriteria penerimaan yang telah ditetapkan, termasuk kesesuaian dengan spesifikasi fungsional (respons benar terhadap input valid dan invalid), tidak adanya kegagalan kritis seperti *error* atau *crash*, kinerja yang efisien tanpa *delay* berarti, serta kepatuhan terhadap standar pengujian seperti uji positif dan negatif, sehingga tidak memerlukan revisi besar sebelum *deployment*.

5.2 Saran

Berdasarkan hasil penelitian dan implementasi sistem prediksi hasil produksi kelapa sawit menggunakan model *LSTM* serta sistem antarmuka berbasis *website*, beberapa saran berikut dapat dipertimbangkan untuk pengembangan dan peningkatan sistem di masa mendatang:

1. Volume data sangat memengaruhi akurasi model prediktif berbasis *LSTM*. Oleh karena itu, disarankan untuk terus menambah dan memperkaya dataset historis, khususnya dari tahun-tahun sebelumnya maupun data harian, agar model dapat belajar pola musiman dan fluktuasi dengan lebih baik serta mengurangi potensi *overfitting*.
2. Saat ini, model hanya mempertimbangkan curah hujan, pemupukan, dan hasil produksi. Untuk meningkatkan performa prediksi, disarankan menambahkan variabel lain seperti suhu, kelembaban udara, jenis pupuk, kondisi tanah, atau jenis varietas tanaman kelapa sawit yang digunakan.
3. Saat ini, model hanya mempertimbangkan curah hujan, pemupukan, dan hasil produksi. Untuk meningkatkan performa prediksi, disarankan menambahkan variabel lain seperti suhu, kelembaban udara, jenis pupuk, kondisi tanah, atau jenis *varietas* tanaman kelapa sawit yang digunakan.
4. Diperlukan pengembangan sistem notifikasi *real-time* serta validasi data input yang lebih ketat agar petugas lapangan tidak salah menginputkan data, khususnya dalam *volume* pupuk dan hasil produksi.

DAFTAR PUSTAKA

- [1] Lubis, R. E., & Lontoh, A. P. (2016). Manajemen Panen Kelapa Sawit (*Elaeis guineensis* Jacq.) di Kebun Adolina, Serdang Bedagai, Sumatera Utara. *Buletin Agrohorti*, 4(2), 144–154. <https://doi.org/10.29244/agrob.v4i2.15013>
- [2] A. Alatas, “Trend Produksi dan Ekspor Minyak Sawit (CPO) Indonesia,” *AGRARIS: Journal of Agribusiness and Rural Development Research*, vol. 1, no. 2, pp. 114–124, 2015, doi: 10.18196/agr.1215.
- [3] M. Arsyad, A. Amiruddin, Suharno, and S. Jahroh, “Competitiveness of Palm Oil Products in International Trade: An Analysis between Indonesia and Malaysia,” *Caraka Tani: Journal of Sustainable Agriculture*, vol. 35, no. 2, pp. 157–167, Oct. 2020, doi: 10.20961/carakatani.v35i2.41091.
- [4] A. J. Astari and J. C. Lovett, “Does the rise of transnational governance ‘hollow-out’ the state? Discourse analysis of the mandatory Indonesian sustainable palm oil policy,” *World Dev*, vol. 117, pp. 1–12, May 2019, doi: 10.1016/j.worlddev.2018.12.012.
- [5] M. Ula, G. Perdinanta, R. Hidayat, and I. Sahputra, “Analyze the Clustering and Predicting Results of Palm Oil Production in Aceh Utara,” *IJCCS (Indonesian Journal of Computing and Cybernetics Systems)*, vol. 17, no. 2, Apr. 2023, doi: 10.22146/ijccs.83195.
- [6] “Pemanfaatan Model Neural Network Dalam Generasi Baru Pertanian Presisi Di Perkebunan Kelapa Sawit.”
- [7] K. Aqbar and R. A. Supomo, “Performance Analysis of LSTM and XGBoost Models Optimization in Forecasting Crude Palm Oil (CPO) Production at Palm Oil Mill (POM),” *Int J Comput Appl*, vol. 185, no. 17, pp. 37–44, Jun. 2023, doi: 10.5120/ijca2023922890.
- [8] K. Aqbar and R. A. Supono, “Performance Analysis of LSTM and XGBoost Models Optimization in Forecasting Crude Palm Oil (CPO) Production at Palm Oil Mill (POM),” 2023.
- [9] F. Ramadhan and M. Fachrie, “Implementasi Algoritma Long Short-Term Memory (Lstm) Pada Sistem Prediksi Hasil Panen Sawit,” *Jurnal Informatika Teknologi dan Sains*, 2024.
- [10] D. Sartika Ginting and S. Ramadhani Kamal, “Palm Oil Production Prediction Using Long Short-Term Memory Method,” *J Theor Appl Inf Technol*, vol. 15, no. 21, 2024, [Online]. Available: www.jatit.org
- [11] Masykur, “Pengembangan Industri Kelapa Sawit Sebagai Penghasil Energi Bahan Bakar Alternatif Dan Mengurangi Pemanasan Global (Studi di Riau Sebagai Penghasil Kelapa Sawit Terbesar di Indonesia),” Juli-Desember, 2013.
- [12] S. Habibi Nasution, C. Hanum, and J. Ginting, “Pertumbuhan Bibit Kelapa Sawit (*Elaeis Guineensis* Jacq.) Pada Berbagai Perbandingan Media Tanam Solid Decanter Dan Tandan Kosong Kelapa Sawit Pada Sistem Single Stage The Growth of Palm Oil (*Elaeis guineensis* Jacq.)

- Seedlings in Various Comparison of Media Solid Decanter and Oil Palm Empty Fruit Bunch at Single Stage System,” vol. 2, no. 2, pp. 691–701, 2014, [Online]. Available: <http://BPPT-HUMAS.ac.id.>,
- [13] S. Habibi Nasution, C. Hanum, and J. Ginting, “Pertumbuhan Bibit Kelapa Sawit (*Elaeis Guineensis* Jacq.) Pada Berbagai Perbandingan Media Tanam Solid Decanter Dan Tandan Kosong Kelapa Sawit Pada Sistem Single Stage The Growth of Palm Oil (*Elaeis guineensis* Jacq.) Seedlings in Various Comparison of Media Solid Decanter and Oil Palm Empty Fruit Bunch at Single Stage System,” vol. 2, no. 2, pp. 691–701, 2014, [Online]. Available: <http://BPPT-HUMAS.ac.id.>,
- [14] J. Homepage, A. Roihan, P. Abas Sunarya, and A. S. Rafika, “IJCIT (Indonesian Journal on Computer and Information Technology) Pemanfaatan Machine Learning dalam Berbagai Bidang: Review paper,” 2019.
- [15] K. Smagulova and A. P. James, “A survey on LSTM memristive neural network architectures and applications,” *European Physical Journal: Special Topics*, vol. 228, no. 10, pp. 2313–2324, Oct. 2019, doi: 10.1140/EPJST/E2019-900046-X.
- [16] “RNN (Recurrent Neural Network): Cara Kerja dan Implementasi - Algoritma.” Accessed: Mar. 28, 2025. [Online]. Available: <https://algoritma.blog/rnn-adalah-2022/>
- [17] M. Haris, T. Pustaka, M. H. Diponegoro, S. Kusumawardani, and I. Hidayah, “Tinjauan Pustaka Sistematis: Implementasi Metode Deep Learning pada Prediksi Kinerja Murid (Implementation of Deep Learning Methods in Predicting Student Performance: A Systematic Literature Review),” 2021.
- [18] A. Khumaidi, R. Raafi, I. Permana Solihin, and J. Rs Fatmawati, “Pengujian Algoritma Long Short Term Memory untuk Prediksi Kualitas Udara dan Suhu Kota Bandung,” *Jurnal Telematika*, vol. 15, no. 1.
- [19] J. Cahyani, S. Mujahidin, and T. P. Fiqar, “Implementasi Metode Long Short Term Memory (LSTM) untuk Memprediksi Harga Bahan Pokok Nasional,” *Jurnal Sistem dan Teknologi Informasi (JustIN)*, vol. 11, no. 2, p. 346, Jul. 2023, doi: 10.26418/justin.v11i2.57395.
- [20] “Jurnal 24 (Pengembangan dan Studi Progressive Web Apps)”.
- [21] S. Aripin and S. Somantri, “Implementasi Progressive Web Apps (PWA) pada Repository E-Portofolio Mahasiswa,” *Jurnal Eksplora Informatika*, vol. 10, no. 2, pp. 148–158, Mar. 2021, doi: 10.30864/eksplora.v10i2.486.
- [22] P. Dokumen, K. Kecamatan, and L. Kurniati, “Penerapan Metode Prototype Pada Perancangan Sistem,” 2021. [Online]. Available: <https://journal-computing.org/index.php/journal-sea/index>
- [23] “Metode SDLC Dalam Pengembangan Software - Dicoding Blog.” Accessed: Apr. 09, 2025. [Online]. Available: <https://www.dicoding.com/blog/metode-sdlc/>

- [24] A. R. Wijaya, “Model Prediksi Data Harga Minyak Mentah Dunia Dengan Metode Exponential Smoothing,” 2023.
- [25] F. Indra Sanjaya and D. Heksaputra, “Prediksi Rerata Harga Beras Tingkat Grosir Indonesia dengan Long Short Term Memory,” vol. 7, no. 2, pp. 163–174, 2020, [Online]. Available: <http://jurnal.mdp.ac.id>
- [26] M. Ardian *et al.*, “Perbandingan Model Regresi Untuk Memprediksi Harga Jual ...549.” [Online]. Available: <https://hargajateng.org/tabel-harga->
- [27] “New Script - Earth Engine Code Editor.” Accessed: Jul. 14, 2025. [Online]. Available: <https://code.earthengine.google.com/?project=ee-muhammadrival040303>

LAMPIRAN

Lampiran 1. *Script Pembuatan Dataset Dummy*

```
import pandas as pd
import numpy as np

np.random.seed(42)

# 20 tahun data bulanan
months = pd.date_range(start='2005-01-01', periods=240,
freq='M')
tahun = months.year
bulan = months.month

# Curah hujan musiman
curah_hujan = 200 + 100 * np.sin(2 * np.pi * bulan / 12) +
np.random.normal(0, 15, 240)

# Pemupukan musiman (kg)
pemupukan = 300 + 50 * np.cos(2 * np.pi * bulan / 6) +
np.random.normal(0, 5, 240)

# Normalisasi fitur ke 0-1
def normalize(x):
return (x - x.min()) / (x.max() - x.min())

curah_hujan_n = normalize(curah_hujan)
pemupukan_n = normalize(pemupukan)

# Gabungkan fitur musiman dan tambahkan tren tahun
combined = (
0.5 * curah_hujan_n +
0.5 * pemupukan_n
)

# Tambah tren tahun dan acakan ringan
trend = (tahun - 2005) / 19 # dari 0 ke 1
random_factor = np.random.uniform(0.9, 1.1, 240)

# Hitung hasil produksi dalam range 50 juta - 80 juta
base_production = 50_000_000
production_range = 30_000_000
hasil_produksi = base_production + ((combined + 0.2 * trend) *
random_factor) * production_range

# Buat DataFrame
df = pd.DataFrame({
'bulan': months.strftime('%d/%m/%Y'),
'curah_hujan': np.round(curah_hujan, 2),
'pemupukan': np.round(pemupukan, 2),
'hasil_produksi': np.round(hasil_produksi).astype(int)
})
```

```
})  
  
# Simpan ke CSV  
df.to_csv('dataset_lstm_terbaru.csv', index=False)
```

Lampiran 2. *Script* Pengambilan Data Curah Hujan

```
// Definisikan ROI (contoh: polygon Jawa Barat)
var roi = ee.Geometry.Polygon([
  [
    [97.34459802411389, 4.122294740126089],
    [98.26744958661389, 4.122294740126089],
    [98.26744958661389, 4.823273940269145],
    [97.34459802411389, 4.823273940269145],
    [97.34459802411389, 4.122294740126089]
  ]
]);

// Tambahkan ROI ke peta untuk visualisasi (opsional)
Map.addLayer(roi, {color: 'red'}, 'ROI');
Map.centerObject(roi, 7); // Zoom ke ROI

var image=ee.ImageCollection("UCSB-CHG/CHIRPS/DAILY")
var data=image.filterDate('2021-01-1', '2025-06-1')
print(data)
var preci=data.map(function(data){
  return data.clip(roi)
})
var precipitation=preci.select('precipitation')
print(precipitation, 'precipitation')
Map.addLayer(precipitation)
```

Lampiran 3. Hasil Perhitungan MAE

Actual	Predicted	Selisih Absolut
73,869,472	73,751,464	118,008
76,781,680	74,923,500	1,858,180
71,038,688	70,327,290	711,398
60,685,667	60,611,228	74,439
57,181,597	58,479,656	1,298,059
58,833,499	67,581,256	8,747,757
69,016,501	74,025,370	5,008,869
77,811,453	76,293,410	1,518,043
75,519,884	75,050,344	469,540
70,823,032	72,722,050	1,899,018
71,863,277	71,668,504	194,773
72,316,115	73,310,640	994,525
75,089,717	74,204,680	885,037
75,517,631	75,735,240	217,609
67,925,203	70,638,590	2,713,387
60,052,111	59,186,360	865,751
58,391,632	55,520,650	2,870,982
62,087,742	60,662,616	1,425,126
71,657,497	72,143,370	485,873
76,634,556	74,258,360	2,376,196
74,958,627	74,136,024	822,603
72,624,534	72,593,960	30,574
68,749,253	73,152,330	4,403,077
73,048,006	73,773,330	725,324
75,035,740	74,448,020	587,720
82,321,504	74,855,656	7,465,848
69,644,583	67,022,532	2,622,051
63,510,004	58,565,920	4,944,084
57,679,112	57,820,340	141,228
64,319,169	66,204,090	1,884,921
70,047,997	73,445,610	3,397,613
77,508,124	74,498,770	3,009,354
73,913,682	73,841,840	71,842
72,996,419	72,641,816	354,603
68,470,328	72,102,660	3,632,332

73,841,480	74,098,280	256,800
78,475,227	74,678,936	3,796,291
73,908,239	75,394,970	1,486,731
69,183,816	70,919,600	1,735,784
61,067,971	62,017,144	949,173
58,071,403	58,012,276	59,127
62,118,864	68,629,890	6,511,026
72,602,135	73,392,800	790,665
76,401,201	74,261,690	2,139,511
Total Kesalahan Absolut		86,550,852
Jumlah Data		44
MAE		1,967,065

Lampiran 4. Hasil Perhitungan RMSE

Actual	Predicted	Selisih	Error
73,869,472	73,751,464	118,008	13,925,888,064
76,781,680	74,923,500	1,858,180	3,452,832,912,400
71,038,688	70,327,290	711,398	506,087,114,404
60,685,667	60,611,228	74,439	5,541,164,721
57,181,597	58,479,656	-1,298,059	1,684,957,167,481
58,833,499	67,581,256	-8,747,757	76,523,252,531,049
69,016,501	74,025,370	-5,008,869	25,088,768,659,161
77,811,453	76,293,410	1,518,043	2,304,454,549,849
75,519,884	75,050,344	469,540	220,467,811,600
70,823,032	72,722,050	-1,899,018	3,606,269,364,324
71,863,277	71,668,504	194,773	37,936,521,529
72,316,115	73,310,640	-994,525	989,079,975,625
75,089,717	74,204,680	885,037	783,290,491,369
75,517,631	75,735,240	-217,609	47,353,676,881
67,925,203	70,638,590	-2,713,387	7,362,469,011,769
60,052,111	59,186,360	865,751	749,524,794,001
58,391,632	55,520,650	2,870,982	8,242,537,644,324
62,087,742	60,662,616	1,425,126	2,030,984,115,876
71,657,497	72,143,370	-485,873	236,072,572,129
76,634,556	74,258,360	2,376,196	5,646,307,430,416
74,958,627	74,136,024	822,603	676,675,695,609
72,624,534	72,593,960	30,574	934,769,476
68,749,253	73,152,330	-4,403,077	19,387,087,067,929
73,048,006	73,773,330	-725,324	526,094,904,976
75,035,740	74,448,020	587,720	345,414,798,400
82,321,504	74,855,656	7,465,848	55,738,886,359,104
69,644,583	67,022,532	2,622,051	6,875,151,446,601
63,510,004	58,565,920	4,944,084	24,443,966,599,055
57,679,112	57,820,340	-141,228	19,945,347,984
64,319,169	66,204,090	-1,884,921	3,552,927,176,241
70,047,997	73,445,610	-3,397,613	11,543,774,097,769
77,508,124	74,498,770	3,009,354	9,056,211,497,316
73,913,682	73,841,840	71,842	5,161,272,964

72,996,419	72,641,816	354,603	125,743,287,609
68,470,328	72,102,660	-3,632,332	13,193,835,758,224
73,841,480	74,098,280	-256,800	65,946,240,000
78,475,227	74,678,936	3,796,291	14,411,825,356,681
73,908,239	75,394,970	-1,486,731	2,210,369,066,361
69,183,816	70,919,600	-1,735,784	3,012,946,094,656
61,067,971	62,017,144	-949,173	900,929,383,929
58,071,403	58,012,276	59,127	3,496,002,129
62,118,864	68,629,890	-6,511,026	42,393,459,572,676
72,602,135	73,392,800	-790,665	625,151,142,225
76,401,201	74,261,690	2,139,511	4,577,507,319,121
Total Kuadrat Error			353,225,553,654,007
Rata-rata Kuadrat Error			8,027,853,492,137
RMSE			2,833,347

Lampiran 5. Hasil Perhitungan *R2 Score*

Actual	Predicted	Rata-rata Aktual	SS Residual	SS Total
73,869,472	73,751,464	69,686,557	13,925,888,064	17,496,775,805,768
76,781,680	74,923,500	69,761,044	3,452,832,912,400	49,289,327,232,166
71,038,688	70,327,290	69,593,886	506,087,114,404	2,087,452,268,803
60,685,667	60,611,228	69,907,890	5,541,164,721	85,049,397,830,248
57,181,597	58,479,656	70,025,571	1,684,957,167,481	164,967,661,690,689
58,833,499	67,581,256	70,046,301	76,523,252,531,049	125,726,918,412,802
69,016,501	74,025,370	70,274,870	25,088,768,659,161	1,583,492,854,753
77,811,453	76,293,410	70,317,849	2,304,454,549,849	56,154,099,035,415
75,519,884	75,050,344	70,305,210	220,467,811,600	27,192,820,580,715
70,823,032	72,722,050	70,238,285	3,606,269,364,324	341,928,664,178
71,863,277	71,668,504	70,328,843	37,936,521,529	2,354,487,316,748
72,316,115	73,310,640	70,187,470	989,079,975,625	4,531,128,471,703
75,089,717	74,204,680	70,251,027	783,290,491,369	23,412,919,706,428
75,517,631	75,735,240	70,392,090	47,353,676,881	26,271,170,115,553
67,925,203	70,638,590	70,325,032	7,362,469,011,769	5,759,179,429,227
60,052,111	59,186,360	70,377,474	749,524,794,001	106,613,126,244,450
58,391,632	55,520,650	70,419,802	8,242,537,644,324	144,676,867,534,815
62,087,742	60,662,616	70,406,459	2,030,984,115,876	69,201,050,446,411
71,657,497	72,143,370	70,407,756	236,072,572,129	1,561,853,504,387
76,634,556	74,258,360	70,447,116	5,646,307,430,416	38,284,419,425,420
74,958,627	74,136,024	70,437,392	676,675,695,609	20,441,562,157,529
72,624,534	72,593,960	70,240,817	934,769,476	5,682,106,736,089
68,749,253	73,152,330	70,132,466	19,387,087,067,929	1,913,278,832,102
73,048,006	73,773,330	70,198,334	526,094,904,976	8,120,633,221,558
75,035,740	74,448,020	70,055,850	345,414,798,400	24,799,305,408,078
82,321,504	74,855,656	69,793,750	55,738,886,359,104	156,944,609,734,829
69,644,583	67,022,532	69,097,764	6,875,151,446,601	299,010,897,246
63,510,004	58,565,920	69,065,598	24,443,966,599,055	30,864,627,960,833
57,679,112	57,820,340	69,412,823	19,945,347,984	137,679,972,364,807
64,319,169	66,204,090	70,195,070	3,552,927,176,241	34,526,216,479,068
70,047,997	73,445,610	70,614,778	11,543,774,097,769	321,240,216,149
77,508,124	74,498,770	70,658,376	9,056,211,497,316	46,919,046,609,697
73,913,682	73,841,840	70,087,564	5,161,272,964	14,639,180,862,983
72,996,419	72,641,816	69,739,735	125,743,287,609	10,605,991,860,105
68,470,328	72,102,660	69,414,066	13,193,835,758,224	890,642,167,635

73,841,480	74,098,280	69,518,926	65,946,240,000	18,684,471,161,781
78,475,227	74,678,936	68,978,607	14,411,825,356,681	90,185,791,424,400
73,908,239	75,394,970	67,621,947	2,210,369,066,361	39,517,467,109,264
69,183,816	70,919,600	66,574,232	3,012,946,094,656	6,809,930,392,779
61,067,971	62,017,144	66,052,315	900,929,383,929	24,843,683,116,599
58,071,403	58,012,276	67,298,401	3,496,002,129	85,137,487,478,505
62,118,864	68,629,890	70,374,067	42,393,459,572,676	68,148,371,067,741
72,602,135	73,392,800	74,501,668	625,151,142,225	3,608,225,618,089
76,401,201	74,261,690	76,401,201	4,577,507,319,121	0
Jumlah			353,225,553,654,007	1,784,138,929,448,540
R2 Score			0.80	